

摘要

TFT-LCD 顯示器電路瑕疵偵測與辨識面臨的挑戰，主要來自瑕疵的多樣性與微觀尺度的限制。本研究針對小尺寸 TFT-LCD 顯示器電路，提出一套綜合解決方案，以有效應對這些挑戰。本研究首先應用影像疊加、連通物件標籤 (Connected Component Labeling) 及形態學運算等影像處理技術，精確識別並隔離電路範圍內的非電路物件，為後續更精確的瑕疵偵測奠定基礎。此外，針對瑕疵特性，將其區分為宏觀與微觀兩大類，並分別採取適應性的偵測與分類策略。在瑕疵辨識方面，本研究運用預訓練集成網路 (Pre-trained Ensemble Network) 方法，結合來自製造商生產線的真實數據，以提升資訊提取的精確度。此方法不僅增強了系統對新型瑕疵的識別能力，同時也提高了辨識模型的靈活性與準確性。

針對可用樣本數量有限的挑戰，本研究引入模擬生成瑕疵影像與 SMOTE (Synthetic Minority Over-sampling Technique) 演算法，以改善正常電路與瑕疵樣本之間的不平衡問題，進而提升模型的泛化能力。本研究所提出的方法顯著提升了 TFT-LCD 顯示器電路瑕疵偵測與辨識的效率與準確性，並為未來相關研究提供了寶貴的參考與啟示。

關鍵詞：瑕疵偵測、瑕疵辨識、微觀瑕疵、小尺寸 TFT-LCD 電路

目錄

摘要.....	錯誤! 尚未定義書籤。
目錄.....	ii
表目錄.....	v
圖目錄.....	vi
第一章 緒論.....	1
1.1 研究動機.....	1
1.2 研究目的.....	3
1.3 研究問題.....	4
1.4 研究目標.....	5
1.5 報告章節.....	6
第二章 文獻探討.....	7
2.1 TFT-LCD 顯示器電路的瑕疵類型	7
2.2 瑕疵偵測範圍的決定	8
2.3 訓練資料的不平衡解法	9
第三章 檢測區域定位	11
3.1 檢測瑕疵分類	11
3.2 檢測樣本的特徵影像	13

3.3 檢測區域定位	16
第四章 宏觀瑕疵偵測與辨識	
4.1 影像預處理	21
4.2 數據平衡處理	23
4.3 建構網路模型	25
第五章 微觀瑕疵檢測與識別	
5.1 構建模擬數據	29
5.2 訓練模型.....	30
第六章 實驗結果.....	
6.1 產生檢測區域的遮罩影像	35
6.1.1 影像疊加處理	36
6.1.2 影像二值化處理	37
6.1.3 影像形態學處理	38
6.2 特徵影像預影像	41
6.2.1 垂直線和水平線的定位	41
6.2.2 檢測區域角點的定位	42
6.2.3 切割子影像	43
6.3 數據平衡處理.....	43
6.4 訓練模型.....	45

第七章 結論與未來方向	50
7.1 結論.....	50
7.2 討論.....	51
7.3 未來規劃.....	52
參考文獻.....	53

表目錄

表 4.1、宏觀瑕疵分類.....	22
表 4.2、模型訓練時的超參數設定值.....	28
表 5.1、9 種不同的像素狀態.....	29
表 5.2、擴增前後的影像數量比較.....	31
表 5.3、模型訓練時的超參數設定值.....	34
表 6.1、計算出遮罩與人工標註區域之間的準確率.....	40
表 6.2、在圖 6.7 中，六條線的方程式.....	42
表 6.3、宏觀瑕疵數據平衡前後的編號分布.....	45
表 6.4、微觀瑕疵數據平衡前後的編號分布.....	45
表 6.5、宏觀瑕疵模型的比較結果.....	46
表 6.6、微觀瑕疵模型的比較結果.....	46
表 6.7、宏觀模型的驗證結果.....	47
表 6.8、微觀模型的驗證結果.....	48

圖目錄

圖 3.1、點型瑕疵範例	11
圖 3.2、線型瑕疵範例.....	12
圖 3.3、區域型瑕疵範例	12
圖 3.4、整體的瑕疵檢測與辨識流程.....	13
圖 3.5、每一個檢驗樣本使用的 10 張特徵影像.....	14
圖 3.6、檢測區域定位處理流程	16
圖 3.7、二值化影像	17
圖 3.8、遮罩影像(形態學處理前).....	19
圖 3.9、完成的遮罩影像	19
圖 3.10、10 張專用於檢測的影像(C0 至 C9)	20
圖 4.1、網路架構圖.....	27
圖 5.1、原始影像圖.....	30
圖 5.2、擴增後的影像.....	31
圖 5.3、使用函數前後比較圖.....	32
圖 6.1、存在毛邊的影像分割結果.....	35
圖 6.2、影像疊加後的結果影像.....	36
圖 6.3、影像二值化後結果.....	38
圖 6.4、二值影像經過形態學處理	39

圖 6.5、原始影像.....	39
圖 6.6、僅包含電路區域	39
圖 6.7、決定檢測區域的 4 條垂直線.....	41
圖 6.8、定義檢測區域的 8 個矩形角.....	42
圖 6.9、分割成 154 張子影像中的前 60 張	43
圖 6.10、分割影像分類.....	43
圖 6.11、圖編號 03029	49
圖 6.12、03029 檢測結果.....	49
圖 6.13、圖編號 13107.....	49
圖 6.14、13107 檢測結果.....	49

第一章 緒論

1.1 研究動機

在現代顯示技術製造領域中，TFT-LCD顯示器電路瑕疵的偵測與分類具有極其重要的地位。首先，這是一種關鍵的品質控制手段，它確保TFT-LCD顯示器能夠達到高品質的標準。在生產過程中，瑕疵的偵測與分類能夠及時識別並排除不合格品，從而保障了最終產品的品質。此外，有效的瑕疵偵測不僅有助於減少因品質問題而產生的退貨和廢品，從而降低生產成本，而且還能提升客戶的滿意度，對於品牌形象和市場競爭力的提升也具有顯著的正面效應。

TFT-LCD顯示器的應用範圍極為廣泛，根據其尺寸可以分為小尺寸、中尺寸及大尺寸三大類型。小尺寸TFT-LCD顯示器，通常是指對角線長度小於10英寸的顯示器；這類顯示器主要被應用於手持和攜帶式設備，例如智慧手機、可穿戴設備和數位相機等。中尺寸TFT-LCD顯示器的對角線長度一般介於10英寸到30英寸之間；它們經常被使用於個人電腦、筆記型電腦、小型電視和車載顯示系統等領域。至於大尺寸TFT-LCD顯示器，則是指對角線長度超過30英寸的顯示器；這一類型的顯示器主要用於大型電視、公共顯示屏幕以及專業級顯示器，如會議室或廣告用顯

示器等。根據歷年的統計數據，這三種尺寸類型的顯示器在產能與應用範圍上均維持了一定的市場占比，保持著各自製造產業的高需求。特別是小尺寸顯示器，由於較早形成產業鏈，在生產技術上較為成熟。然而，在引入新型生產技術和瑕疵檢測技術方面，進展相對較為緩慢和落後。本研究旨在針對小尺寸TFT-LCD顯示器電路瑕疵，提出更為有效的檢測與辨識技術，以降低誤判率，進而提升產品的整體價值。

TFT-LCD顯示器電路瑕疵偵測與辨識是一項具有高度挑戰性的工作。首先，這些瑕疵的類型相當多樣，依照單張感測影像能被觀察的程度，大致可劃分為宏觀瑕疵和微觀瑕疵兩大類[1, 2]。宏觀瑕疵主要包括那些能夠輕易被肉眼察覺的瑕疵，如Mura(光亮不均勻)、光洩漏、閃頻等；而像素點發光不良、黑白光點及刮痕、灰塵微粒等由於其尺寸較小，則被劃分為微觀瑕疵。然而，大多數關於TFT-LCD顯示器電路瑕疵檢測的研究重點主要集中在宏觀瑕疵上，尤其是Mura[3-5]。另一方面，整個電路影像掃描的像素可能達到數億個，而某些瑕疵僅涉及2-3個像素。因此，一個優質的TFT-LCD顯示器電路瑕疵偵測與辨識系統需要解決瑕疵偵測與辨識的多樣性問題、提升辨識準確性，同時降低計算複雜度，以提高執行速度。

基於以上的論述，本研究將著重於針對小尺寸TFT-LCD顯示器電路的多類型瑕疵偵測與辨識技術研究與開發。相較於中大尺寸的TFT-LCD

顯示器電路，小尺寸TFT-LCD顯示器電路在檢測執行上具備以下特色：

- (1) **複雜的影像感測環境**：在一個影像感測過程中，可能同時包含多個電路的影像，這意味著檢測影像中可能包括檢測設備的其他組件，而非僅是電路的某一局部區域。
- (2) **高度同質性與規律性**：與一般的積體電路(IC)相比，TFT-LCD顯示器電路是由以像素為基礎的大型陣列組成，其具有顯著的同質性和規律性。
- (3) **主動發光的能力**：TFT-LCD顯示器能主動發光，因此在檢測時可以通過顯示不同內容來使瑕疵在不同的特徵影像中顯現，這與傳統固定電路的檢測對象存在顯著差異。
- (4) **亮度分布的變化**：由於背光或LCD本身的瑕疵，TFT-LCD顯示器可能產生不同的亮度分布，使得瑕疵的成像變化較大。

這些特性意味著對小尺寸TFT-LCD顯示器電路進行瑕疵檢測與分類所需的技術，與用於中大尺寸TFT-LCD顯示器電路的方法存在顯著差異，需要解決不同的技術問題。

1.2 研究目的

在本研究中，將致力於開發和優化小尺寸 TFT-LCD 電路的瑕疵檢測技術。首先，利用單一攝影機來取得能夠分辨不同類型瑕疵的特徵影

像，這對於瑕疵的定位與分類具有重要價值。為了提高檢測精度，將採用影像處理技術來自動偵測和定位小尺寸 TFT-LCD 電路的檢測區域，同時清除目標區域外的環境干擾。

為了更有效地處理瑕疵檢測，本研究引入多重 CNN 網路的集成技術，特別是針對現行和區域型的 mura 類型瑕疵。這種集成技術能夠實現自動化的高精準瑕疵定位和類型識別，大大提高了檢測的準確性和效率。最後，系統遵循 ISO/TR 9241-310 標準的規範，能對 TFT-LCD 顯示器電路的次像素進行瑕疵類型、位置和數量的全面檢測，確保了檢測結果的可靠性和準確性。透過這些技術的整合，本研究期望能夠為 TFT-LCD 電路的瑕疵檢測提供一個高效、精確的解決方案。

1.3 研究問題

本研究針對小尺寸TFT-LCD電路進行其瑕疵偵測與辨識的系統研發。基於前述的實務需求，預期中的研究問題與解決方案說明如下：

(1) **檢測區域定位**:不像大尺寸電路是以掃描方式進行局部區域的檢測，因此不會有電路以外的物件出現在檢測區域內。而小尺寸電路則是能同時觀看到數個電路，因此會觀察到電路間的置具、檢測設備與背景等非電路的物件，需要加以遮蔽，以免干擾瑕疵的偵測與辨識。本研究將應用影像疊加、聯通物件標籤、形態學等影像處理技術，自動完

成一個感測區域內多個電路範圍的定位任務。

- (2) **宏觀瑕疵類型辨識**：傳統方法在處理多樣瑕疵辨識時，可能需要手動設計多個規則或過濾器，且對於新的瑕疵類型難以適應，使得整個辨識系統不夠靈活。本研究規劃採用深度學習方法，直接由製造商生產線取得的真實數據中，訓練集成式深度模型，達成自動化的高精準瑕疵定位與類型識別。
- (3) **微觀瑕疵檢測與識別**：針對ISO/TR 9241-310標準[6]的微觀次像素瑕疵檢測，傳統方法需要複雜的手動設置，且準確度受限於先前定義的檢測模型，難以應對不斷變化的檢測需求。本研究為每個像素產生多重特徵，再藉由這些特徵分布，以語意分割的檢測方式，訓練結合注意力機制的改良式U-Net，進行像素級的瑕疵類別識別與標註。

1.4 研究目標

基於本研究的目標，本研究期望開發出一個能夠高效且準確地進行小尺寸TFT-LCD電路瑕疵檢測與辨識的系統。具體而言，本研究的目標包括：

- (1) **模型定位正確率達到95%以上**：在對小尺寸TFT-LCD電路瑕疵的自動檢測中，模機能夠準確定位瑕疵所在的檢測區域，並保證瑕疵定位的正確率達到95%以上，以確保高效的瑕疵檢測。
- (2) **瑕疵辨識準確率達到95%以上**：系統應能準確辨識出多種類型的瑕

疵尤其是針對宏觀和微觀瑕疵，辨識準確率需達到95%以上，以確保檢測結果的可靠性。

(3) 執行速度小於2秒：在實際生產環境中，為了滿足工業快速生產的需求，整個瑕疵檢測與辨識過程的執行速度應控制在2秒以內。

這些目標將通過實驗數據進行驗證，並在最終實驗結果中進行詳細示以確保本研究的成果在實際應用中的可行性和有效性。

1.5 報告章節

本報告在其餘章節介紹如下，在第三章介紹瑕疵分類及檢測樣本的特徵，最後介紹如何定位檢測區。在第四章和第五章介紹透過影像預處理、數據平衡、及模型訓練過程。第六章討論實驗結果。在第七章說明結論與未來方向。

第二章 文獻探討

2.1 TFT-LCD 顯示器電路的瑕疵類型

本研究著重於 TFT-LCD 顯示器電路中瑕疵的偵測與辨識，其中以 Mura 瑕疵為主要研究對象[3, 7]。在日語中，“Mura”是指“不均勻”或“斑點”，專門用來描述 TFT-LCD 顯示器中的一種特殊瑕疵。Mura 瑕疵表現為液晶顯示器上亮度或色彩不均勻的區域，這些不均勻現象通常來自於製造過程的不一致性或材料瑕疵。這類瑕疵會在顯示器上形成斑點、條紋或雲狀的暗區或亮區，而影響顯示器的整體視覺效果。

Mura 瑕疵一般分為點瑕疵、線瑕疵和區域瑕疵三種類型[8, 9]，它們主要根據外觀特徵和形狀進行區分，每種瑕疵類型可能需要不同的檢測和分類方法。隨著 LCD 技術的發展，Mura 瑕疵的出現機率也在增加。因此，檢測 Mura 瑕疵是一項具有挑戰性的任務，可以從以下幾個方面來證明：(1) Mura 瑕疵通常出現在亮度不均且對比度低的局部區域[10]，因此在變化的光照條件下較難以識別；(2) Mura 瑕疵沒有固定的大小和規則的形狀，使得同一類型的瑕疵表現出較大的差異，而不同類型的瑕疵可能表現出較小的差異，容易導致誤分類[11]；(3) 一些 Mura 故障的樣本相對較為罕見，這導致識別系統中樣本數據的嚴重不平衡，增加了識別 Mura 瑕疵的難度。

2.2 瑕疵偵測範圍的決定

由於小尺寸 TFT-LCD 顯示器電路的成像面積相對較小，這使得在一次感測程序中可以包含多個電路，從而提高生產和檢測的速度。然而，這種方法的一個挑戰是，在非電路區域也可能包含了生產和檢測環境中的置物、驅動電路和檢測平台，這就導致了在偵測前需要獲得特定的偵測遮罩(detection mask)。在此背景下，Li 等人[12]基於電腦視覺技術，通過邊緣檢測和閾值分割，進行基於形狀的模板匹配以確定感興趣的區域(ROI)。然而，這種方法主要針對影像中的單一電路有效。Jian 等人[13]則採用形態學中的開運算去除雜訊，並使用 Otsu 法則來獲得電路區域的二值影像。隨後，他們利用邊緣檢測算子從二值影像中提取出圖案輪廓。由於不變量僅依賴於物體的幾何形狀，因此即使在物體位移和旋轉的情況下，它們也能保持不變。顯然，這些方法仍然局限於單一電路的偵測遮罩求取，對於複數電路的情況仍然存在不同方法開發的需求。

在瑕疵偵測範圍的決定方面，除了已提及的方法外，還有一些其他的技術和策略可以應用。這些方法可能包括但不限於：

- (1) 基於機器學習的方法：利用機器學習技術，如卷積神經網路(CNN)或他的變種，可以有效地識別感興趣的區域。這些模型可以通過訓練來學習區分電路區域和非電路區域，並且可以通過結合不同層次的

特徵來提高準確性。

- (2) 多尺度檢測：考慮到電路可能存在的不同尺度和旋轉變化，可以使用多尺度檢測方法來應對這些情況。這些方法可以通過在不同尺度下對影像進行檢測，並將結果組合起來，從而提高對電路區域的覆蓋範圍。
- (3) 特徵匹配：利用電路的特徵訊息，如形狀、大小、位置等，可以進行特徵匹配來識別感興趣的區域。這些特徵可以通過模板匹配、特徵提取和描述符匹配等技術來實現。
- (4) 半監督學習：對於一些可能缺乏標註數據的場景，可以採用半監督學習的方法。這種方法通常結合有監督學習和無監督學習技術，利用少量標註數據和大量未標註數據來進行模型訓練，從而擴展模型對於不同情況的適應能力。

瑕疵偵測範圍的決定是一個具有挑戰性的問題，需要綜合考慮多種因素並選擇合適的技術和方法。未來的研究可以進一步探索這些方法的組合和改進，以應對不斷變化的生產和檢測需求。

2.3 訓練資料的不平衡解法

在瑕疵偵測的應用中，如果不考慮不平衡問題，訓練出來的模型可能會傾向於大多數樣本所屬的類別，而忽略少數類別。這將導致模型的

偏差，使在預測少數類別時表現不佳。通常會面臨訓練資料不平衡的情況，即某些類別的樣本數量遠多於其他類別。這可能會導致模型對於少數類別的預測效果不佳。為了解決這個問題，目前一些常見的作法包括以下幾種：

- (1) 過採樣 (Over-sampling)：這個方法是通過增加少數類別的樣本數量來平衡各個類別之間的數量差異。常見的過採樣方法包括隨機複製樣本、SMOTE (Synthetic Minority Over-sampling Technique) 等。
- (2) 欠採樣 (Under-sampling)：與過採樣相反，欠採樣是通過減少多數類別的樣本數量來平衡數據集。這樣可以減少對計算資源的需求，但可能會損失一些訊息。
- (3) 結合抽樣 (Sampling Combination)：結合過採樣和欠採樣的方法，通常可以更好地平衡數據集，提高模型的性能。
- (4) 類別加權 (Class Weighting)：在訓練過程中，對不同類別的損失函數進行加權，使得模型更關注少數類別的預測效果。

以上方法通常都可以有效地處理訓練資料不平衡的問題[14]，但需要根據具體應用場景和數據集特點來選擇最適合的方法。

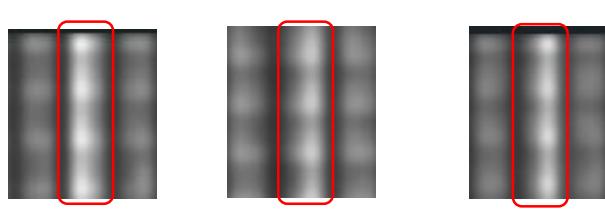
第三章 檢測區域定位

3.1 檢測瑕疵分類

LCD 面板的生產過程極為複雜，涵蓋了多個精密製造階段。在此過程中，可能出現各種瑕疵，這些瑕疵會影響產品的性能和品質。一些常見的瑕疵類別及其可能的生成原因包括：

(1) 點型瑕疵：此類型包括亮點、暗點及顏色異常點等，其生成原因可能來源於塵埃、污垢或製造過程中材料的雜質。這些瑕疵在顯示外觀上，由於像素中三個 LCD 單元各自的瑕疵和組合而形成的次像素瑕疵，需要在微觀層次進行細緻的識別。如圖 3.1 所示。

(2) 線型瑕疵：包括垂直線和水平線等類型，其產生原因可能為源線或閘線的瑕疵或損壞。這些瑕疵可能由物理損傷、製程不良或材料問題導致，並對顯示器的視覺效果造成顯著影響。線瑕疵如圖 3.2 所示。



(a) 紅畫面 I_7 (b) 綠畫面 I_8 (c) 藍畫面 I_9

圖 3.1、點型瑕疵範例

(3) 區域型瑕疵：此類瑕疵為液晶顯示器中常見的畫面品質問題，主要表現為顯示幕某一區域內的亮度或色彩不均勻。瑕疵類型包括黑漏光、色彩偏差、亮度不均勻等，其產生原因可能是液晶分佈不均、材料老化或壓力不均等導致的液晶或光學層性能異常。在外觀上，這些瑕疵在形狀和大小上可能呈現極大的變化，從小塊斑點到大片區域均有可能出現。此外，區域型 Mura 瑕疵的分佈通常是隨機的，可能出現在屏幕的任何位置。如圖 3.3 所示。

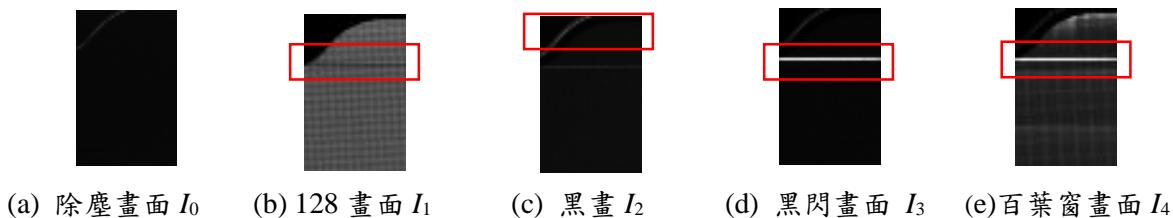


圖 3.2、線型瑕疵範例

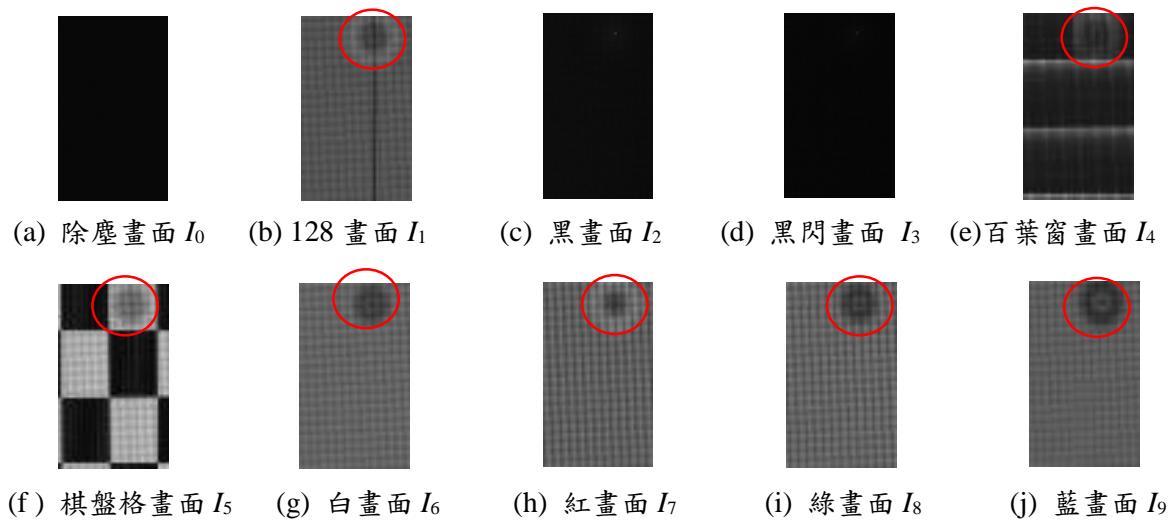


圖 3.3、區域型瑕疵範例

本研究針對這三種瑕疵進行檢測與辨識，其中點型瑕疵屬於微觀瑕疵，而線型與區域型瑕疵則屬於宏觀瑕疵，可透過肉眼直接觀察。

本研究將瑕疵檢測與辨識任務透過建構網路模型來完成，整體的瑕疵檢測與辨識流程如圖 3.4 所示，各個處理單元將分述如下。

3.2 檢測樣本的特徵影像

為了能夠有效地檢測並識別顯示器上的各種可能瑕疵，透過同一台攝影機加上驅動電路控制，就能產生顯示器的多張特徵影像，對於顯露不同類型的瑕疵極為有效。這些特徵影像能夠從不同的角度和條件下展示待檢測樣本的顯示特性，使各種潛在的瑕疵被清楚地顯示出來。多張特徵影像重要性的幾個關鍵點包括：

(1) 不同顯示條件下的瑕疵顯示：不同的顯示條件(如亮度、對比度、顏色設置等)可能會使某些瑕疵更加明顯。例如，一個點型或區域型瑕疵在高亮度下可能很難被發現，但在低亮度或特定顏色設置下可能變

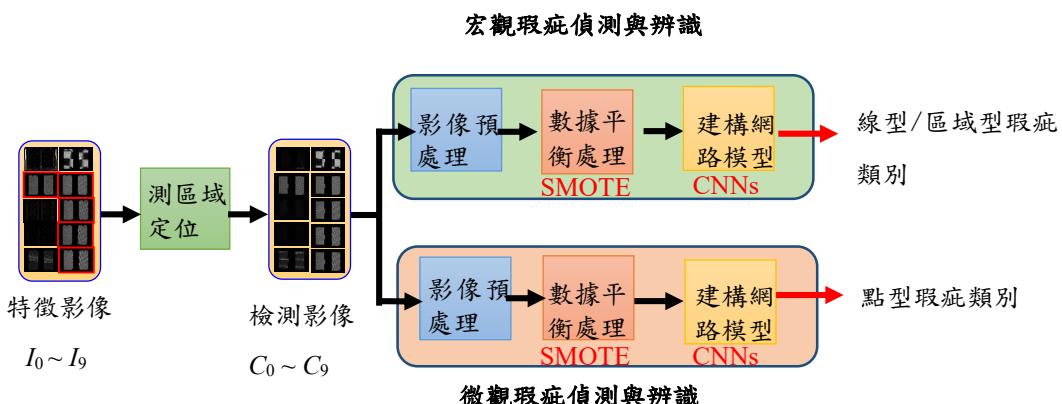


圖 3.4、整體的瑕疵檢測與辨識流程

得非常顯著。

(2) **全面的瑕疵檢測**：通過多張特徵影像，可以從不同的視角和環境設

置中檢測瑕疵，從而提高檢測的全面性和準確性。

(3) **增加數據豐富性**：多張特徵影像提供了更多的數據，這對於使用深

度學習或其他數據驅動的方法來檢測瑕疵非常重要，因為這些方法依

賴於大量的數據來訓練和改進其識別模型。

(4) **特定瑕疵類型的識別**：某些特定類型的瑕疵可能只有在特定的顯示

條件下才能被識別出來。例如，一些色彩相關的點型瑕疵可能只有在

展示特定顏色範圍時才會出現。

基於上述的考量，本研究將使用多張特徵影像，以增強瑕疵檢測的

效率和準確性，還可以確保對各種可能的瑕疵類型進行全面的檢測，從

而提高整體顯示品質。規劃對每一個樣本使用的 10 種特徵影像，如圖

3.5 所示，各特徵影像的設計原則說明如下：

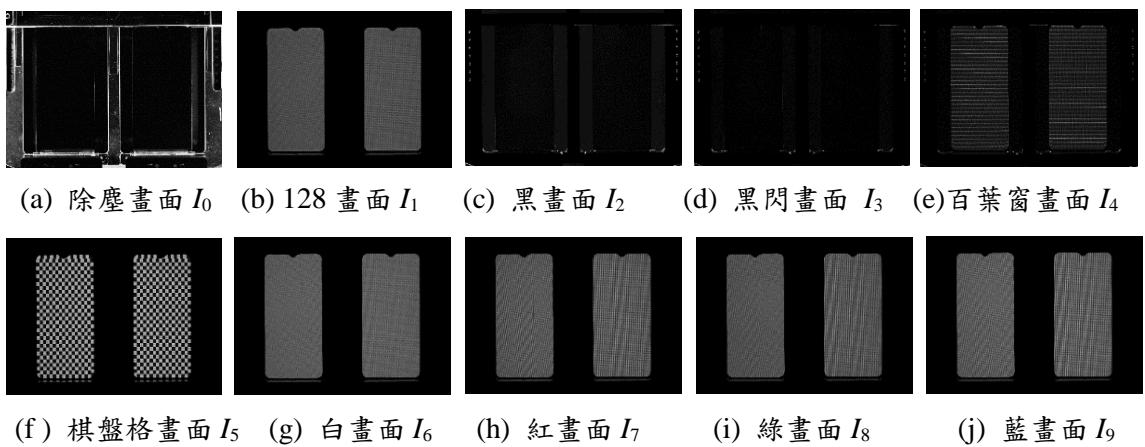


圖 3.5、每一個檢驗樣本使用的 10 張特徵影像

- (1) 除塵畫面 I_0 ：由於面板表面會存在灰塵顆粒，不能將這些顆粒視為瑕疵。在不點亮 LCD 面板時(全黑畫面)，可在影像上找到白點的灰塵顆粒，需要將其遮罩為非瑕疵，如圖 3.5(a)所示。
- (2) 128 畫面 I_1 ：以灰階皆為 128 的影像顯示，可以取得無法點亮或永遠點亮的像素位置，如圖 3.5(b)所示。
- (3) 黑畫面 I_2 ：以灰階皆為 0 的影像顯示，可以取得永遠點亮的像素位置，如圖 3.5(c)所示。
- (4) 黑閃畫面 I_3 ：以低於 60 Hz 的頻率，顯示黑畫面。用以觀察在低頻時，LCD 漏電的情況(無法高速顯示黑色)，如圖 3.5(d)所示。
- (5) 百葉窗畫面 I_4 ：以百葉窗影像顯示(每個帶狀圖形的灰階由 255 至 0 均勻分布)，觀察觸控區域(方格區域)的短路現象，同時監看四周觸控區域的互動狀況(充放電影響)，如圖 3.5(e)所示。
- (6) 棋盤格畫面 I_5 ：以棋盤格影像顯示(灰階分別為 255(白色)與 0(黑色)的方格間錯分布，大小同觸控區域)，觀察觸控區域(方格區域)的短路現象，若發生就會在影像中顯示較淡的顏色，如圖 3.5(f)所示。
- (7) 白畫面 I_6 ：以灰階皆為 255 的影像顯示，可以取得永遠無法點亮的像素位置(可能是 R/G/B 點之一)，如圖 3.5(g)所示。
- (8) 紅畫面 I_7 ：以紅色影像顯示，可以取得永遠無法點亮紅點的像素位置，如圖 3.5(h)所示。

(9) 綠畫面 I_8 ：以綠色影像顯示，可以取得永遠無法點亮綠點的像素位置，如圖 3.5(i)所示。

(10) 藍畫面 I_9 ：以藍色影像顯示，可以取得永遠無法點亮藍點的像素位置，如圖 3.5(j)所示

3.3 檢測區域定位

針對小型TFT-LCD顯示器電路影像，常見的挑戰之一是一張影像中會存在多個顯示器電路，並有許多電路以外的背景元件。在此情形下，有必要將影像的前景區域(即電路部分)與背景區域進行有效分割。這一步驟對於精準定位檢測區域並排除非目標區域的干擾至關重要，尤其是在瑕疵檢測和識別過程中。整個檢測區域定位的處理流程如圖3.6所示。考慮到每個樣本包含10張特徵影像(分別標記為 I_0 至 I_9)，在分析這些特徵影像時，特別關注於那些能呈現較為完整且亮度一致的前景區域之特徵影像。此外，因為使用相同的攝影機對不同的顯示畫面取像，不存在TFT-LCD顯示器電路的幾何或投影變化。基於此，選擇以 I_1 、 I_6 、 I_7 、 I_8 和 I_9 這

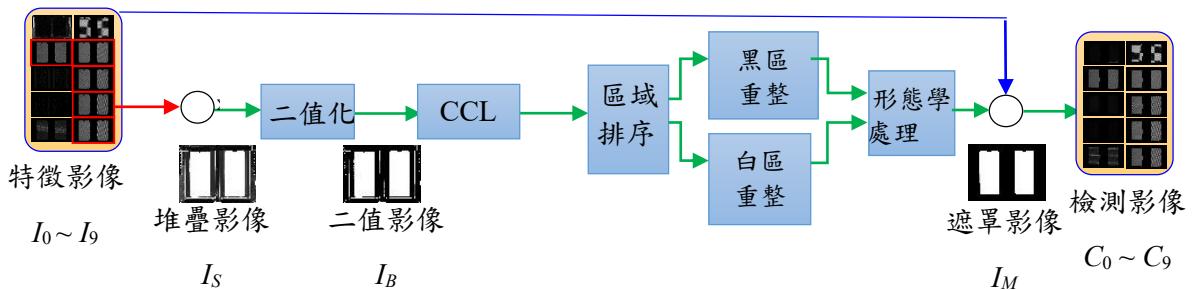


圖 3.6、檢測區域定位處理流程

幾張特徵影像進行疊加處理，以此獲得更加清晰和集中的前景資訊，從而為後續的分析和處理提供更穩定、可靠的基礎。通過這種方法，可以更準確地識別和定位影像中的電路關鍵區域，為瑕疵檢測提供了必要的影像預處理步驟。

$$I_s = \frac{1}{4.5} \sum_{j=1,6,7,8,9} I_j \quad (1)$$

此公式用加權平均計算特定影像亮度，以提升穩定性。

透過此方式，電路區域在疊加後呈現出相對較高的亮度，而背景區域的亮度則相對被壓抑。這種亮度的對比增強，為後續的影像處理奠定了基礎。當進行二值化處理時，電路區域因亮度較高而轉變為白色，背景區域則因亮度較低而呈現為黑色。此方法有效地區分了電路與背景，從而在二值化影像，如圖3.7所示，中清晰地突出了電路區域。這一步驟對於精確識別和定位電路中的特定元件及潛在瑕疵至關重要，進而為瑕疵檢測與辨識提供了清晰且可靠的視覺基礎。

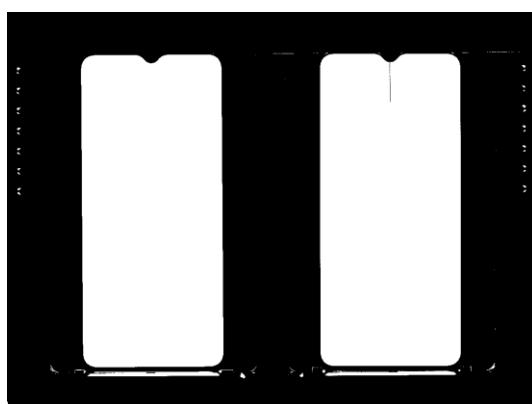


圖3.7、二值化影像

$$I_B = \begin{cases} 255, & I_S > t_B \\ 0, & I_S \leq t_B \end{cases} \quad (2)$$

此公式將影像亮度二值化為黑白，以便後續分析。

然而，值得注意的是，在前景的電路區域中，瑕疵像素通常以黑色呈現，而背景區域中的雜訊與製造過程中的痕跡，則在二值化影像中以白色顯示。為了精確獲得完整且正確的前景與背景區分，首先對二值化影像 I_B 分別進行白色區域與黑色區域的聯通元件標籤處理 (Connected Components Labeling, CCL)，接著根據面積大小對這些區域進行排序，從而得到白色區域集合 $W = \{w_1, w_2, \dots, w_m\}$ 以及黑色區域集合 $B = \{b_1, b_2, \dots, b_n\}$ ，其中 m 與 n 分別為影像 I_B 中的白色區域與黑色區域數量。

在目前處理的特徵影像中，白色區域主要包含兩個電路區域，其他較小的白色區域則大多為背景中的雜訊。因此，針對集合 W 進行重整，僅保留 w_1 與 w_2 作為電路區域，將 I_B 中屬於 w_3 至 w_m 的其他像素由白色改為黑色，以排除非目標區域的干擾。同理，黑色區域代表背景，但其中較小的黑色區域可能為電路中的瑕疵或機台上的置具或驅動電路。因此，對集合 B 進行重整，保留最大的黑色區域 b_1 作為背景，而將在 I_B 中屬於 b_2 至 b_n 的其他像素由黑色改為白色。此過程確保了電路與背景的有效分離，並為後續瑕疵檢測提供了清晰且準確的基礎。遮罩 (mask) 影像 (形態學處理前) 如圖 3.8 所示。

為了確保前景電路區域的完整性與連續性，本研究在重整後的影像上進行了形態學中的閉運算(Close)。此操作目的在於填補前景電路區域內的小孔洞和斷裂，同時平滑化邊界，而不對物體的總面積造成顯著變化。這一步驟對於確保電路區域的結構完整性和視覺清晰度極為關鍵。如圖3.9所示。

經閉運算處理後的結果影像被定義為遮罩影像圖3.9。隨後，將10張特徵影像(I_0 至 I_9)分別與遮罩影像 I_M 進行點乘運算，從而得到10張專用於檢測的影像(C_0 至 C_9)。如圖3.10所示。

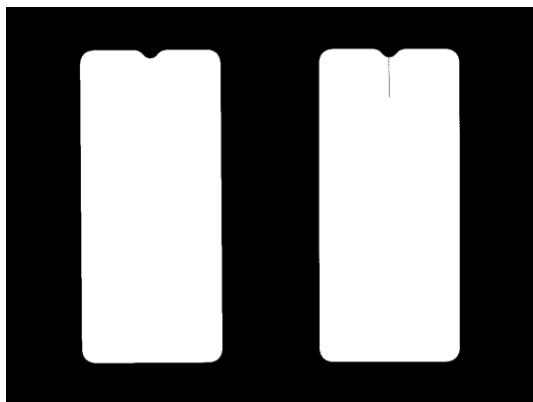


圖 3.8、遮罩影像(形態學處理前)

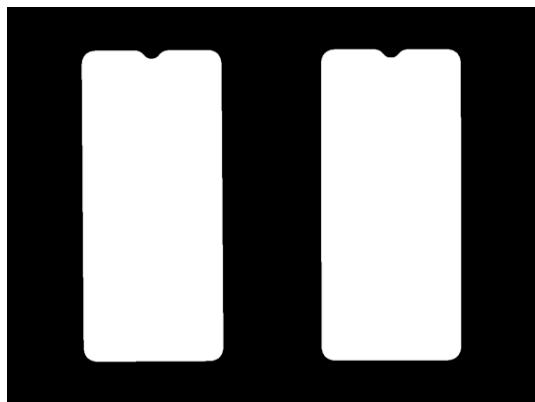


圖 3.9、完成的遮罩影像

$$C_j = I_j \cdot I_M, \quad j = 0, \dots, 9 \quad (3)$$

這一過程確保了所得到的檢測影像僅包含電路區域，從而有效排除了非目標區域的干擾。這些經過篩選和加工的影像成為了後續瑕疵檢測和分析的基礎，確保了分析的準確性和可靠性。通過這樣的處理，可以更集中地關注電路區域的潛在瑕疵，從而提高檢測的效率和精確度。

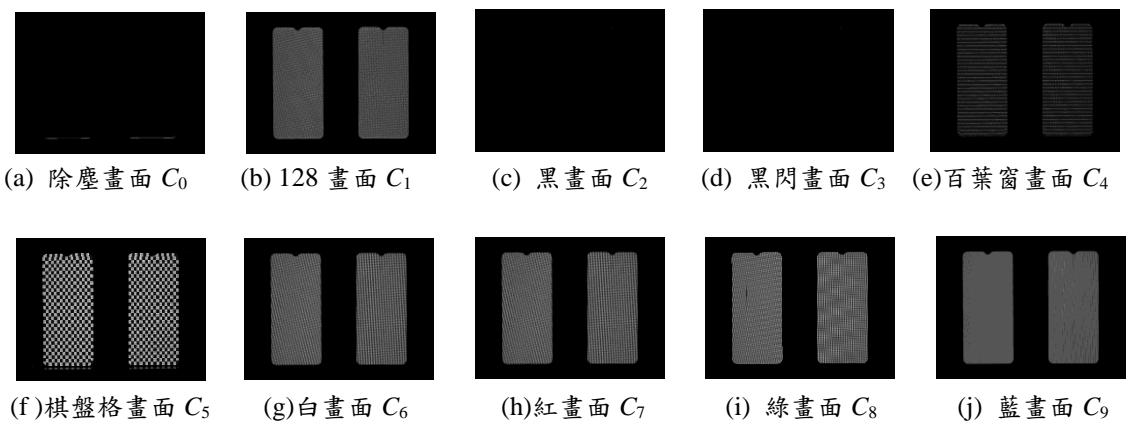


圖 3.10、10 張專用於檢測的影像(C_0 至 C_9)

第四章 宏觀瑕疵偵測與辨識

對於瑕疵檢測的任務而言，皆屬於瑕疵的偵測與辨識處理，但由於宏觀瑕疵與微觀瑕疵在本質上與使用資訊上的差異，本研究將這兩類的瑕疵分別處理，以獲取低複雜度與高效能的分類器。針對超過一個像素點尺寸的線瑕疵與 mura 瑕疵，本研究將其視為一項針對 5 個瑕疵類別的辨識任務，如表 4.1 所示。用於訓練的影像資料來自於某 TFT-LCD 製造商，每張影像均包含兩塊小尺寸的 TFT-LCD 電路，合計涵蓋 200 個樣本，每個樣本均含有 10 張具有特徵的影像。此外，經由檢測系統與人工標註的預處理程序，已對存在的瑕疵進行標識。

整體偵測與辨識流程如下面各節說明。

4.1 影像預處理

鑑於樣本特徵影像的尺寸高達 $9,344 \times 7,000$ 個像素，對於深度學習模型而言，過大的輸入影像可能導致記憶體不足及模型訓練的困難。考慮到宏觀瑕疵具有不同的尺寸與外型，本研究基於計算設備的硬體限制，將特徵影像分割為多個較小的子影像，子影像大小為 60×40 ，透過縮減影像尺寸以縮短模型的訓練時間。由此，每一個子影像將成為一個被檢測的單元，並獲得其分類的輸出標註。

表 4.1、宏觀瑕疵分類

編號	類型	瑕疵類型
0	線	正確無瑕疵
1	線	亮線瑕疵
2	區域	暗線瑕疵
3	區域	黑漏光 Mura
4	區域	亮度色彩 Mura
5	區域	線性 Mura

影像預處理是在進行影像分析或處理前對影像進行的一系列操作，改善影像的質量、提取有用訊息、降低雜訊和消除不必要的細節。影像預處理是影像處理中的一個關鍵步驟，旨在提高影像質量、改善特徵提取、降低雜訊以及使影像更適合後續的分析或處理。其中一個常見的預處理步驟是影像縮放和裁剪。當處理大型影像時，經常會遇到計算資源不足的問題，因此將影像縮放為較小的尺寸可以節省計算資源。此外，裁剪則可以用於去除影像邊緣的不必要部分，或者調整影像的結構，使其更適合特定的應用場景。

其他預處理技術還包括邊緣檢測、色彩校正、補償變形以及影像分割。這些技術都有助於改善影像的質量、提取有用訊息以及使影像更適合後續的分析或處理。影像預處理可以提高後續處理過程的效果和效率。

4.2 數據平衡處理

在瑕疵檢測任務中，存在有瑕疵的影像數量遠少於無瑕疵影像數量的現象，從而導致數據不平衡。若直接使用原始特徵影像進行模型訓練，模型可能會將所有像素歸類為無瑕疵，造成總體分類準確率高，但對少數類別(含瑕疵者)的驗證準確率偏低，導致模型實用性降低。針對不平衡數據集的解決方案之一是對少數類別進行過採樣(oversampling)，即複製少數類別樣本，但此舉不會為模型提供新訊息。相反的，從現有樣本中合成新樣本是一種針對少數類別的數據增強(data augmentation)方法，稱為合成少數類過採樣技術(Synthetic Minority Oversampling Technique, SMOTE)。本研究擬採用 SMOTE 方法處理不平衡資料，其基本原理包括通過生成合成的少數類別樣本來平衡資料集，從而提升模型對少數類別的學習能力。

數據平衡處理是在機器學習和數據分析中常用的技術，用於處理數據集中類別不平衡的問題，即某些類別的樣本數量遠遠超過其他類別的情況。這種不平衡可能導致模型對少數類別的預測效果不佳。需要對數據集中的類別不平衡問題進行深入理解，確定哪些類別是少數類別，它們的樣本數量與其他類別相比存在多大的差距。

平衡處理可能會導致模型對少數類別的過度擬合，因此需要仔細調

節平衡處理方法和模型算法，以避免這種情況的發生。在某些情況下，改變損失函數、調整類別權重等也是處理類別不平衡問題的有效方法。數據平衡處理可以提高模型對所有類別的預測能力和泛化能力，從而改善機器學習模型的性能。

合成少數類別過採樣技術（Synthetic Minority Oversampling Technique, SMOTE）是一種針對機器學習中數據增強的技術，適用於處理不平衡數據集。SMOTE 透過插值現有的少數類別樣本來合成新的樣本，並將其添加到數據集中，以平衡不同類別的樣本數量。SMOTE 的特點是根據少數的類別樣本之間的距離，在原有樣本之間生成新樣本，以避免過度複製現有樣本。其具體工作原理如下。

- (1) 辨識少數樣本：辨識數據集中的少數類別樣本。
- (2) 選擇相鄰樣本：對於每個少數類別樣本，SMOTE 從其最近的幾個少數類別鄰居中隨機選擇一個進行插值。
- (3) 生成合成樣本：通過在選定樣本和其鄰居之間進行線性插值，生成新的合成樣本。這些樣本位於原樣本和鄰居樣本之間，從而填補少數類別樣本之間的間隙。
- (4) 平衡數據集：將合成的少數類別樣本與原始數據集結合，最終形成一個更為平衡的數據集，具體的合成樣本數量取決於所需的平衡程度。

4.3 建構網路模型

目前在物件分類領域中最為廣泛應用的神經網路模型是卷積神經網路(CNN)。然而，這類網路模型通常需要依賴大量的訓練數據集來提高其性能；因此，在數據量有限的情況下，直接將 CNN 應用於 Mura 瑕疵的分類可能會面臨一定的困難。為了解決這一問題，轉移學習成為一種適宜的選擇。轉移學習是指在一個大型且標籤完善影像數據集上對 CNN 進行初始訓練，使其學習到適用於所有影像的通用影像特徵，然後將這些特徵應用於規模較小的數據集中以擷取相關特徵[14, 15]。在轉移學習過程中，整個網路在監督學習的條件下完成訓練後，所得到的特徵提取器可以被進一步訓練或直接重用於特定的應用目的。轉移學習不僅在分類效果上表現良好，還可以顯著降低對訓練數據量的依賴，從而有效提升模型的適應性和應用範圍。因此，轉移學習解決了在樣本數據有限，且分佈不均的多類別分類問題上使用卷積神經網路(CNN)時遇到的挑戰。接著，對預訓練的 CNN 進行微調處理。微調是通過反向傳播使用來更新 CNN 的預訓練權重的過程。對瑕疵影像數據的廣泛研究顯示，微調與從頭開始訓練 CNN 一樣有效，同時對訓練數據的大小更具強健性[16-18]。

建構網路模型是機器學習和深度學習中的一個重要步驟，它涉及選

擇適當的模型架構、定義網路層次和參數，並進行模型訓練和評估。清楚地定義想要解決的問題，確定問題的類型（分類、回歸等）、目標以及評估指標（準確率、MSE 等）。當建構宏觀瑕疵偵測與辨識的網路模型時，會將影像中的不同區域分類為正常或瑕疵。

本研究選用 ResNet50V2 模型，是一種深度卷積神經網路，通過引入「殘差結構」來解決深層網路中常見的梯度消失問題，而提高了深層網路的訓練效果。這種架構允許信息沿捷徑傳遞，避免因層數增加而導致的退化問題。

在 ResNet50V2 中，模型的數據會通過多層網路結構處理，包括卷積層、ReLU 層、池化層和 Batch Normalization 層等。ResNet50V2 包含 53 個卷積層、49 個 ReLU 層、4 個池化層和 49 個 Batch Normalization 層。

(1) 卷積層：ResNet50V2 中有 53 個卷積層，用於提取輸入影像中的特徵。這些卷積層使用不同的過濾器來捕捉影像的邊緣、紋理等不同層次的特徵，並生成特徵圖。卷積操作使得網路能夠捕捉影像中的空間結構特徵。

(2) ReLU 層（修正線性單元層）：共有 49 個 ReLU 層，這些層在每個卷積層之後添加。ReLU 是一種激活函數，將輸入中的負值轉換為零，從而引入非線性，使模型具有更強的表達能力，並幫助解決梯

度消失問題。

(3) 池化層：ResNet50V2 包含 4 個池化層，用於降低特徵圖的空間維度，這樣可以減少模型的參數量並加快計算速度。池化層幫助模型保留重要特徵，同時丟棄不重要的信息，從而提高模型的計算效率。

(4) Batch Normalization 層：ResNet50V2 中 49 個 Batch Normalization 層，這些層有助於穩定和加速模型的訓練過程，通過對每一層的輸入進行標準化來減少內部協變轉移，進而提高模型的泛化能力。在 ResNet50V2 模型中，殘差塊是模型的核心，它們允許信息繞過某些層，從而使得深層網路更容易訓練。整體上，這種架構能夠有效地學習影像中的複雜特徵，從而實現高效的影像分類。ResNet50V2 的模型訓練超參數設定值如表 4.1 所示，網路架構圖如 4.1 所示。

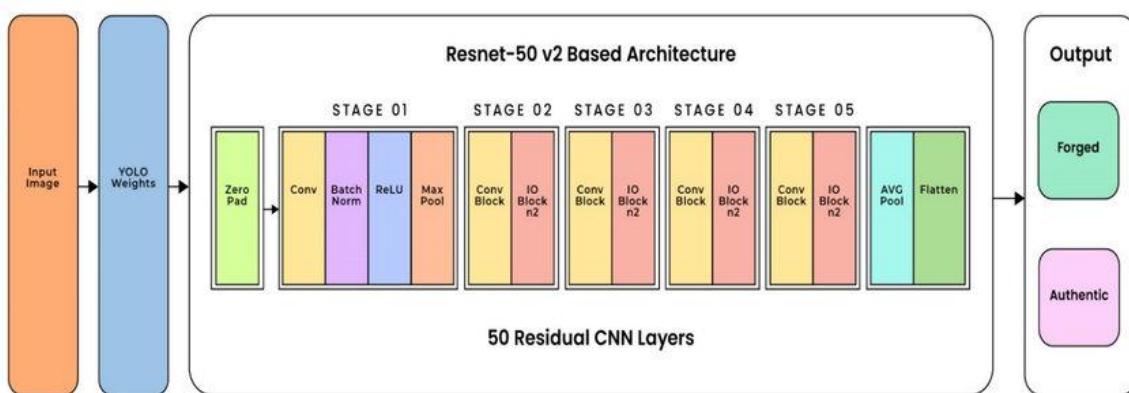


圖 4.1、網路架構圖

表 4.2、模型訓練時的超參數設定值

超參數	設定值
學習率 (Learning Rate)	0.01
動量 (Momentum)	0.9
批次大小 (Batch Size)	32
訓練周期 (Epochs)	100
損失函數 (Loss Function)	categorical_crossentropy
激活函數 (Activation Function)	Softmax
輸入形狀 (Input Shape)	(60, 40, 7)
類別數量 (Number of Classes)	6
優化器 (Optimizer)	SGD
訓練準確率(TrainingAccuracy)	0.99790172
驗證準確率(ValidatioAccuracy)	0.994032901
訓練損失 (Training Loss)	0.005635022
驗證損失 (ValidationLoss)	0.02402557

第五章 微觀瑕疵檢測與識別

在微觀瑕疵檢測的研究範疇內，本研究首先明確界定每個像素所涵蓋的要素：

- (1) 液晶顯示器 (LCD) 的三原色：紅色 (R, Red)、綠色 (G, Green)、藍色 (B, Blue)；
- (2) 五種不同的輸出狀態：無瑕疵 (DF, Defect-Free)、全亮瑕疵 (FL, Full-Light)、全暗瑕疵 (FD, Full-Dark)、半亮瑕疵 (HL, Half-Light)。

基於上述定義，共可組合出 9 種不同的像素狀態。如表 5.1 所示。

表 5.1、9 種不同的像素狀態

編號	類型	紅畫面	綠畫面	藍畫面
0	正確無瑕疵	○ ● ●	● ○ ●	● ● ○
1	R 全亮瑕疵	○ ● ●	○ ○ ●	○ ● ○
2	R 半亮瑕疵	● ● ●	● ○ ●	● ● ○
3	R 全暗瑕疵	● ● ●	● ○ ●	● ● ○
4	G 全亮瑕疵	○ ○ ●	● ○ ●	● ○ ○
5	G 半亮瑕疵	○ ● ●	● ● ●	● ● ○
6	G 全暗瑕疵	○ ● ●	● ● ●	● ● ○
7	B 全亮瑕疵	○ ● ○	● ○ ○	● ● ○
8	B 半亮瑕疵	○ ● ○	● ○ ○	● ● ○
9	B 全暗瑕疵	○ ● ●	● ○ ●	● ● ●

根據所定義的像素狀態，本研究將其視為一項針對 12 個類別的辨識任務。用於訓練的影像資料來自於某 TFT-LCD 製造商的影像資料，每

張影像均包含兩塊小尺寸的 TFT-LCD 電路，合計涵蓋 200 個樣本，每個樣本均含有 10 張具有特徵的影像。但因為微觀數據較少，所以本研究對微觀數據進行了模擬生成以達到實驗目的。此外，經由檢測系統與人工標註的預處理程序，也將同於宏觀瑕疵的辨識流程，根據先前的標註進行重新標註以提供更為明確的表示。此外，在影像預處理與數據平衡處理方面，皆採用同宏觀瑕疵辨識的處理方式。

5.1 構建模擬數據

在微觀瑕疵檢測研究中，尤其是在面對數據稀少的情況下，模擬數據生成技術是一種非常有效的解決方案。這一技術的目的是通過擴展數據集，提供更多可用的訓練樣本，從而提高模型的泛化能力與準確性。當前，本研究結合了 OpenCV 的 goodFeaturesToTrack 函數和自定義的 generate_similar_image 函數來實現數據擴增。利用圖 5.1 生成出多張影像，再利用人工分類的方式，組合出表 5.1 中的 9 種瑕疵類型。如圖 5.2 為一組增生後影像。表 5.2 為增前後的影像數量比較。

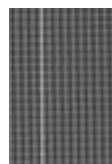


圖 5.1、原始影像圖

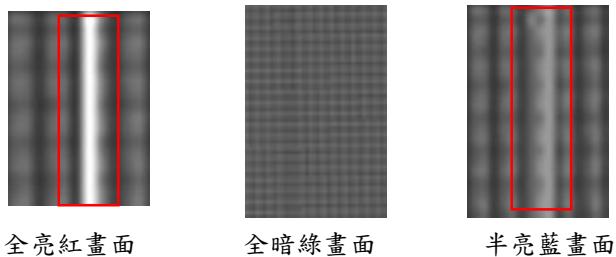


圖 5.2、擴增後的影像

表 5.2、擴增前後的影像數量比較

編號	擴增前	擴增後
0	3,012	3,012
1	6	26
2	0	20
3	1	21
4	4	24
5	15	35
6	6	26
7	49	69
8	1	21
9	6	26

在進行數據模擬生成之前，首先需要對圖像進行特徵提取。特徵提取的目的是找出圖像中最重要、最具代表性的部分，以便後續生成的圖像能夠保持與原始圖像一致的結構與語義訊息。為此，研究中使用了 OpenCV 提供的 goodFeaturesToTrack 函數。該函數是一種基於角點檢測的方法，能夠在圖像中識別出顯著特徵，特別適合檢測圖像中的細微變化，這對於微觀瑕疵檢測來說至關重要。

具體來說，goodFeaturesToTrack 函數會根據角點、邊緣等關鍵特徵

對圖像進行分析，並返回一組具有高對比度或重要性的特徵點。這些特徵點是隨機變化和雜訊添加的基礎，因為它們反映了圖像的局部結構，能夠顯示出微小的瑕疵或者無瑕疵區域的區別。

在獲得了圖像的顯著特徵後，下一步就是基於這些特徵來生成新的相似圖像。為此，本研究設計了 `generate_similar_image` 函數，其核心思想是在保持圖像主要特徵不變的前提下，通過引入隨機變化來生成新的圖像，從而模擬出微小差異。

這個過程中，隨機變化通常會體現在像素值的改變、噪聲的引入，或者是局部圖像的變形。通過這些手段，`generate_similar_image` 能夠在保持原始圖像的整體結構和語義特徵的同時，創造出具有細微不同的新圖像。這些新圖像與原始圖像相比，可能會有不同的光影、顏色或者形狀的微小變化，這恰好模擬了實際中可能出現的微觀瑕疵情況。原始影像與使用函數前後比較圖如圖 5.1 所示。

這一過程能夠產生大量的變異圖像，從而有效地擴展數據集。尤其

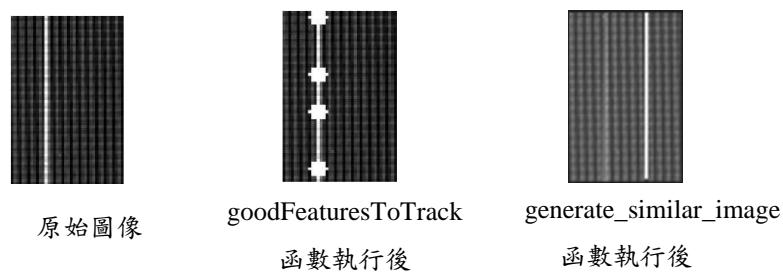


圖 5.3、使用函數前後比較圖

是當研究中涉及微觀瑕疵檢測時，通常難以從實際生產環境中收集到足夠多的瑕疵樣本，因此這種模擬生成技術變得尤為重要。它可以通過數據擴增來模擬多種瑕疵情況，幫助系統學習和識別更多潛在的瑕疵類型，從而提高系統的準確性。

5.2 訓練模型

本研究將數據分為訓練數據、驗證數據和測試數據。訓練和驗證數據用於構建模型，測試數據用於驗證模型的分能力。選擇優化器是模型訓練的重要部分，可以用來計算各種梯度。本研究規劃使用 Adam 作為主要優化器[19]，它可以在防止過擬合方面產生積極影響，並適用於大多數分類問題。

在微觀瑕疵檢測任務中，為了提升分類精度，本研究選用了基於卷積神經網絡（CNN）的 ResNet50V2 模型。ResNet50V2 具備殘差結構，能夠有效避免深層網絡中的梯度消失問題，從而提升模型的學習效果與準確性。由於微觀數據樣本量有限，研究採用了數據擴增技術來增加訓練樣本。通過使用 `analyze_image` 函數來檢測圖像中的顯著特徵，再利用 `generate_similar_image` 函數生成新圖像，加入隨機變化與噪聲，模擬出微小差異，擴充數據集以進行訓練。

在模型訓練過程中，首先對原始數據進行歸一化處理，然後使用預

訓練的 ResNet50V2 模型，並通過遷移學習將其應用到微觀瑕疵檢測任務中。替換了模型的頂層全連接層，以適應 12 個像素狀態分類任務，並使用交叉熵損失函數和 Adam 優化器進行模型編譯。為了進一步提高模型的泛化能力，訓練過程中引入了數據擴增技術，如旋轉、平移、縮放等操作，模擬各種瑕疵場景，增強模型對實際工業應用中瑕疵的檢測能力。微觀瑕疵的網路架構圖和圖 4.1 相同，模型訓練時的超參數設定值如表 5.1 所示。

表 5.3 模型訓練時的超參數設定值

超參數	設定值
學習率 (Learning Rate)	0.01
動量 (Momentum)	0.9
批次大小 (Batch Size)	32
訓練周期 (Epochs)	100
損失函數 (Loss Function)	categorical_crossentropy
激活函數 (Activation Function)	relu (隱藏層)
輸入形狀 (Input Shape)	(60, 40, 3)
類別數量 (Number of Classes)	10
優化器 (Optimizer)	SGD
訓練準確率(Training Accuracy)	0.997186977
驗證準確(Validation Accuracy)	0.997028602
訓練損失 (Training Loss)	0.009699941
驗證損失 (Validation Loss)	0.011360175

第六章 實驗結果

在本章中，將詳細說明本研究的實驗過程與結果，驗證所提出的方法在 TFT-LCD 顯示器電路瑕疵偵測與辨識上的效能。首先，透過影像處理技術生成檢測區域的遮罩影像，包括影像疊加、二值化及形態學處理，以確保檢測範圍的準確性。接著，針對電路的特徵影像，利用垂直與水平線的定位技術確定檢測區域的角點，進一步切割出精細化的子影像，以利後續分析。

此外，為了解決樣本數量不均衡的問題，應用數據平衡技術，透過模擬生成瑕疵樣本及 SMOTE (Synthetic Minority Over-sampling Technique) 方法來提升模型的訓練效果。最後，本章將介紹模型訓練過程，並透過評估指標比較不同方法的辨識效能，以驗證本研究方法的準確性與適應性。這些實驗結果不僅有助於提升 TFT-LCD 電路瑕疵偵測的效能，也為未來相關研究提供重要的參考依據。

6.1 產生檢測區域的遮罩影像

本實驗的目的是精準定位檢測區域並排除非目標區域的干擾。整個檢測區域定位的處理流程如圖 3.6 所示。針對小型 TFT-LCD 顯示器電路影像，常見的挑戰之一是一張影像中會存在多個顯示器電路，並有許多電路以外的背景元件。在此情形下，有必要將影像的前景區域(即電路部

分)與背景區域 進行有效分割。這一步驟對於精準定位檢測區域並排除非目標區域的干擾至關重要，尤其是在瑕疵檢測和識別過程中。此外，在形態化處理後，會發現得出的影像存在毛邊，如圖 6.1 所示。



圖 6.1、存在毛邊的影像分割結果

為了改善提取的檢測影像的質量，需要進一步優化提取影像的方法，以做到更精確的定位。通過再次將形態化處理後的影像進行一次形態學的膨脹與收縮，成功地定位了需要檢測的區域。但仍將繼續努力，不斷優化定位方法，提高效率。

6.1.1 影像疊加處理

考慮到每個樣本包含 10 張特徵影像(分別標記為 I_0 至 I_9)，如圖 3.2 所示，在分析這些特徵影像時，特別關注於那些能呈現較為完整且亮度一致的前景區域之特徵影像。此外，因為使用相同的攝影機對不同的顯示畫面取像，不存在 TFT-LCD 顯示器電路的幾何或投影變化。基於此，選擇以 I_1 、 I_6 、 I_7 、 I_8 和 I_9 這幾張特徵影像進行疊加處理（圖 6.2），以此

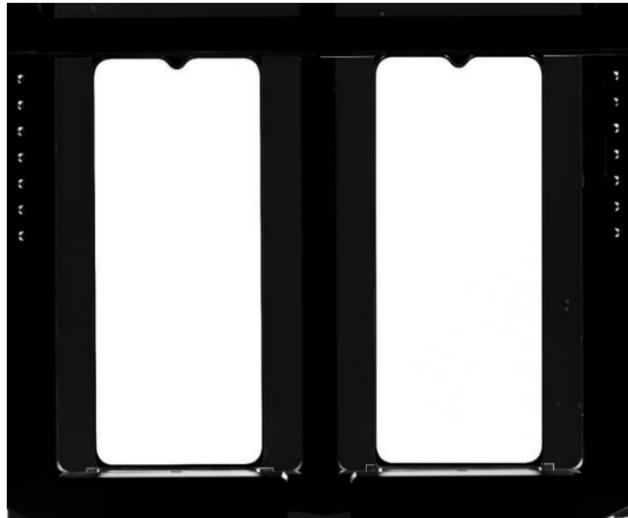


圖 6.2、影像疊加後的結果影像

獲得更加清晰和集中的前景資訊，從而為後續的分析和處理提供更穩定、可靠的基礎。通過這種方法可以更準確地識別和定位影像中的電路關鍵區域，為瑕疵檢測提供了必要的影像預處理步驟。

6.1.2 影像二值化處理

當進行二值化處理時，電路區域因亮度較高而轉變為白色，背景區域則因亮度較低而呈現為黑色。此方法有效地區分了電路與背景，從而在二值化影像中清晰地突出了電路區域。這一步驟對於精確識別和定位電路中的特定元件及潛在瑕疵至關重要，進而為瑕疵檢測與辨識提供了清晰且可靠的視覺基礎。

然而，值得注意的是，在前景的電路區域中，瑕疵像素通常以黑色呈現，而背景區域中的雜訊與製造過程中的痕跡，則在二值化影像中以白色顯示。為了精確獲得完整且正確的前景與背景區分，首先對二值化

影像 I_B 分別進行白色區域與黑色區域的聯通元件標籤處理(Connected Components Labeling, CCL)，接著根據面積大小對這些區域進行排序，從而得到白色區域集合 $W = \{w_1, w_2, \dots, w_m\}$ 以及黑色區域集合 $B = \{b_1, b_2, \dots, b_n\}$ ，其中 m 與 n 分別為影像 I_B 中的白色區域與黑色區域數量。在目前處理的特徵影像中，白色區域主要包含兩個電路區域，其他較小的白色區域則大多為背景中的雜訊。因此，針對集合 W 進行重整，僅保留 w_1 與 w_2 作為電路區域，將 I_B 中屬於 w_3 至 w_m 的其他像素由白色改為黑色，以排除非目標區域的干擾。同理，黑色區域代表背景，但其中較小的黑色區域可能為電路中的瑕疵或機台上的置具或驅動電路。因此，對集合 B 進行重整，保留最大的黑色區域 b_1 作為背景，而將在 I_B 中屬於 b_2 至 b_n 的其他像素由黑色改為白色。此過程確保了電路與背景的有效分離，並為後續瑕疵檢測提供了清晰且準確的基礎，如圖 6.3 所示。

6.1.3 影像形態學處理

為了確保前景電路區域的完整性與連續性，本研究在重整後的影像上進行了形態學中的閉運算(Close)。此操作目的在於填補前景電路區域內的小孔洞和斷裂，同時平滑化邊界，而不對物體的總面積造成顯著變化。

這一步驟對於確保電路區域的結構完整性和視覺清晰度極為關鍵，

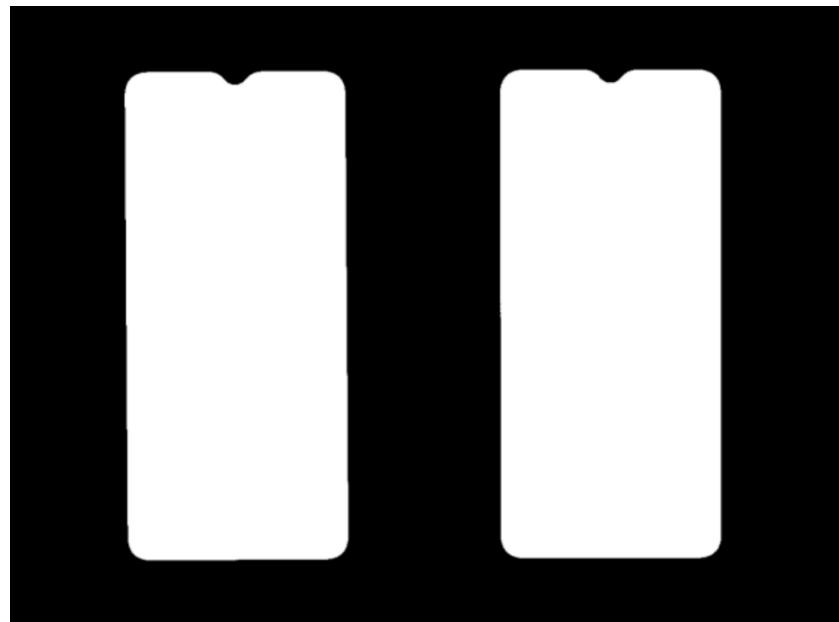


圖 6.3、影像二值化後結果

如圖 6.4 所示。經閑運算處理後的結果影像被定義為遮罩影像 I_M 。隨後，將 10 張特徵影像(I_0 至 I_9)分別與遮罩(Mask) 影像 I_M 進行點乘運算，從而得到 10 張專用於檢測的影像(C_0 至 C_9)。

這一過程確保了所得到的檢測影像僅包含電路區域，從而有效排除了非目標區域的干擾。原始影像如圖 6.5 所示，僅保留電路區域如 6.6 所示，。通過這樣的處理，可以更集中地關注電路區域的潛在瑕疵，從而

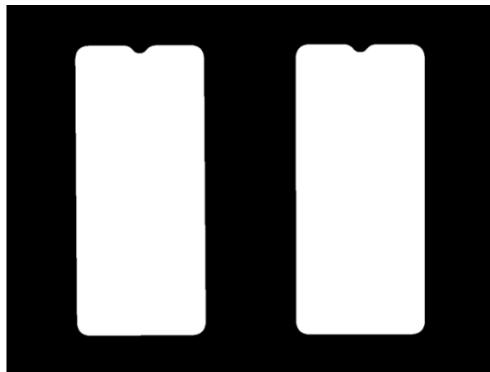


圖 6.4、二值影像經過形態學處理

提高檢測的效率和精確度。

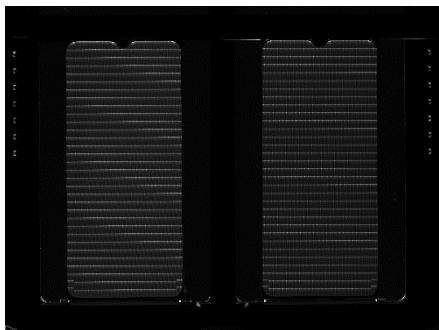


圖 6.5、原始影像



圖 6.6、僅包含電路區域

為確保遮罩區域 mask 和 10 張特徵影像(I_0 至 I_9)的電路區域大小一致，採用了人工描繪出電路區和圖 6.4 的遮罩區域做對比，步驟如下，將人工描繪的電路區和遮罩相加並計算出兩者之間的重疊像素數，基於重疊像素數，計算出遮罩與人工標註區域之間的準確率。針對 10 張特徵影像的具體計算結果，如表 6.1 所示。

表 6.1、計算出遮罩與人工標註區域之間的準確率

	人工描繪	白色重疊區域像素數	黑色重疊區域像素數	正確率
除塵畫面		419,022	596,260	99.34%
128 畫面		419,022	596,264	99.34%
黑畫面		419,019	597,406	99.45%
黑閃畫面		419,022	596,480	99.56%
百葉窗畫面		419,022	596,489	99.37%
棋盤格畫面		419,022	596,542	99.37%

白畫面		419,022	596,001	99.32%
紅畫面		419,022	596,056	99.32%
綠畫面		419,022	595,047	99.32%
藍畫面		419,022	595,627	99.28%

6.2 特徵影像預影像

鑑於樣本特徵影像的尺寸高達 $9,344 \times 7,000$ 個像素，對於深度學習模型而言，過大的輸入影像可能導致記憶體不足及模型訓練的困難。考慮到宏觀瑕疵具有不同的尺寸與外型，本研究基於計算設備的硬體限制，將特徵影像分割為多個較小的子影像，旨在透過縮減影像尺寸以縮短模型的訓練時間。由此，每一個子影像將成為一個被檢測的單元，並獲得其分類的輸出標註。

6.2.1 垂直線和水平線的定位

為了能規則分割影像，首先將決定檢測區域的外包矩形。這個矩形需要由它的四個角點定義，所以需要先找出角點的位置。本研究利用 Hough transforms 演算法找出 4 條垂直線(紅色)和 2 條水平線(綠色)，如圖 6.7 所示。將六條直線用方程式表示，如表 6.1 所示。

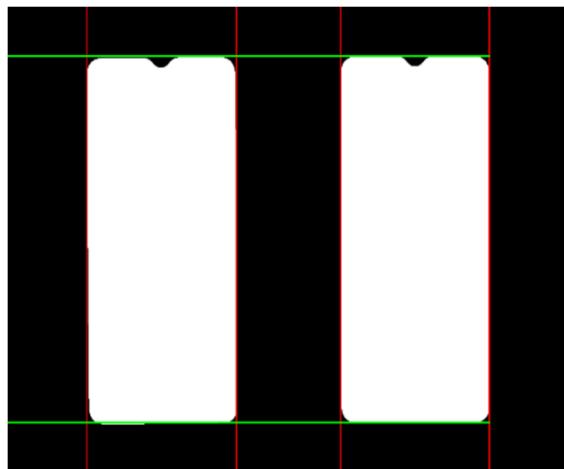


圖 6.7、決定檢測區域的 4 條垂直線

表 6.2、在圖 6.7 中，六條直線的方程式

編號	方程式
1	$X = 164$
2	$X = 167$
3	$X = 474$
4	$X = 690$
5	$Y = 780$
6	$Y = 777$

6.2.2 檢測區域角點的定位

首先將直線的方程式轉化為線性方程組的形式，再使用 `np.linalg.solve()` 函數解決線性方程組，得到交點坐標。如圖 6.8 所示。

6.2.3 切割子影像

設子影像寬/高為 40×60 的切割結果，一張圖片切割完會產生 154

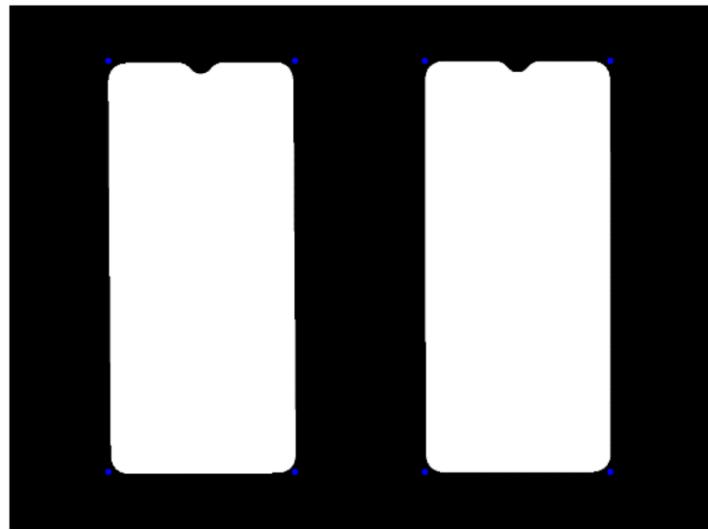


圖 6.8、定義檢測區域的 8 個矩形角
張子影像。圖 6.9 為切割的一部分子影像。



圖 6.9、分割成 154 張子影像中的前 60 張
隨後，透過人工分類的方式，將十張特徵影像中相同位置的分割結
果儲存於同一資料夾中，如圖 6.10 所示。

6.3 數據平衡處理

數據平衡處理 (Data Balancing) 是機器學習和數據處理中的一個重要步驟，主要用於解決數據不平衡問題。在分類任務中，當某些類別的樣本數量遠多於其他類別時，模型往往會偏向預測樣本較多的類別，從而影

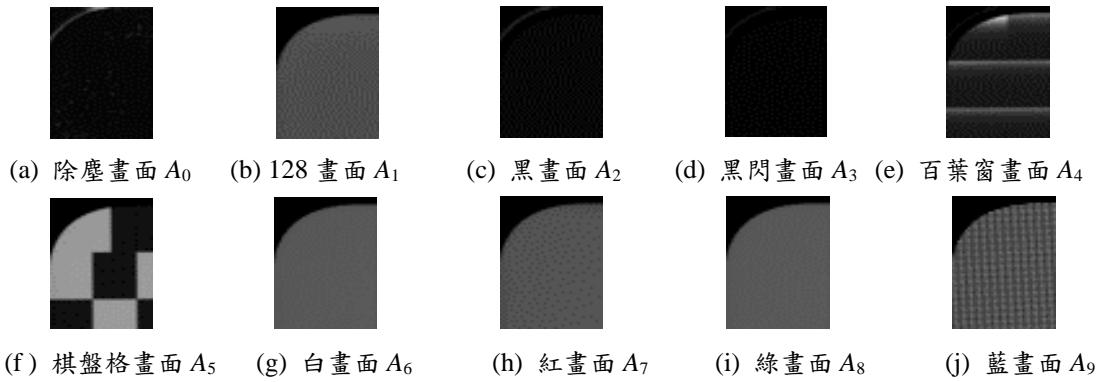


圖 6.10、分割影像分類

響模型的性能和準確度。為了緩解這一問題，數據平衡處理技術應運而生。

透過人工分類後發現，發現在瑕疵的分類中，編號為 0 的無瑕疵類別整體數據中的占比超過 95%。針對宏觀瑕疵分類，未經數據平衡前的編號分布如表 6.3 所示。微觀瑕疵分類，未經數據平衡前的編號分布如表 6.4 所示。針對微觀模型，可以從表 6.3、6.4 發現相較於宏觀瑕疵分類，微觀瑕疵分類中具有瑕疵的圖像數量更少，為了解決數據不平衡問題，採用了 OpenCV 的 `goodFeaturesToTrack` 函數和自定義的 `generate_similar_image` 函數來實現數據擴增，此方法通過模擬生成更多具有瑕疵的圖像，以增加數據集中微觀瑕疵樣本的數量。

為了避免這種類別不平衡對模型訓練的影響，本研究針對宏觀瑕疵和微觀瑕疵都採用了虛擬少數類別過抽樣技術（Synthetic Minority Oversampling Technique, SMOTE）來進行數據平衡，以提高模型對少數類別的識別能力。

表 6.3、宏觀瑕疵數據平衡前後的編號分布

編號	平衡處理前數量	平衡處理後數量
0	5,108	5,108
1	168	5,108
2	101	5,108
3	2	5,108
4	3	5,108
5	8	5,108

表 6.4、微觀瑕疵數據平衡前後的編號分布

編號	平衡處理前數量	平衡處理後數量
0	2,992	2,992
1	6	2,992
2	1	2,992
3	1	2,992
4	4	2,992
5	15	2,992
6	6	2,992
7	49	2,992
8	1	2,992
9	6	2,992

6.4 訓練模型

在完成資料平衡後，本研究將人工標記後的數據及相應的圖片(圖片是以 NumPy 陣列的形式儲存)導入多個深度學習模型進行訓練，在比較各個模型，在瑕疵檢測任務中的表現。透過訓練不同架構的模型，如 ResNet50v2、VGG16 以及其他改良型模型，評估其在識別宏觀與微觀瑕疵的準確性和穩定性。在比較了多個深度學習模型後，宏觀瑕疵模型的比較結果如表 6.5 所示，微觀瑕疵模型的比較結果如表 6.6 所示。本研究最終選擇了 ResNet50v2。

表 6.5、宏觀瑕疵模型的比較結果

	平均驗證損失	平均驗證準確率
mobilenetv2	0.169850633	0.939657421
resnet50	0.022750364	0.993024675
resnet50v2	0.02402557	0.994032901
resnet101v2	0.024948137	0.992482388
vgg16	0.538762336	0.202623338

表 6.6、微觀瑕疵模型的比較結果

	平均驗證損失	平均驗證準確率
mobilenetv2	0.293798079	0.922791037
resnet50	0.066018963	0.992085987
resnet50v2	0.011360175	0.997028602
resnet101v2	0.01353586	0.995567498
vgg16	0.418860609	0.147323739

確定採用 ResNet50v2 模型後，本研究分別針對宏觀瑕疵和微觀瑕疵進行訓練，產生兩個專門針對不同瑕疵類型的模型。首先，將經過分類處理的宏觀瑕疵數據導入 ResNet50v2 模型進行訓練，產生處理宏觀瑕疵的檢測模型。接著，針對微觀瑕疵數據集，同樣使用 ResNet50v2 進行訓練，生成針對微觀瑕疵的檢測模型。

在產生模型後，本研究進行了人工驗證，以評估模型的實際檢測效果。首先，將未經訓練的圖片分別導入宏觀和微觀的 ResNet50v2 模型中進行檢測，並將模型輸出的結果與最初人工分類的結果進行比對。透過對比，計算出宏觀模型的準確率達到 0.9987，如表 6.7 所示，微觀模型則是 0.95238。

表 6.7、宏觀模型的驗證結果

		人工分類標記				
		0	1	2	3	4
預 測 類 別	0	2,990	0	2	0	0
	1	0	11	0	0	0
	2	1	0	6	0	0
	3	0	0	0	0	0
	4	0	0	0	0	0
	5	0	0	0	0	0

表 6.8、微觀模型的驗證結果

		人工分類標記									
		0	1	2	3	4	5	6	7	8	9
預測 類別	0	4,398	2	6	5	9	13	8	5	5	16
	1	1	24	0	0	0	1	0	2	2	0
	2	0	0	14	0	0	0	0	0	0	0
	3	3	0	0	8	0	2	1	0	0	0
	4	0	0	0	0	16	0	1	0	0	1
	5	0	0	0	0	0	24	1	0	1	0
	6	2	1	0	0	9	5	23	0	0	0
	7	3	2	0	0	2	1	4	21	0	0
	8	0	0	0	0	0	0	0	0	32	0
	9	1	0	0	0	0	1	0	0	0	27

最後，將針對宏觀和微觀瑕疵分別訓練出的兩個模型進行結合，產生出一個可以同時預測這兩類瑕疵的系統。此系統先將輸入的圖像數據依據特定通道數進行拆分（前 7 張圖像用於宏觀瑕疵的預測，後 3 張圖像用於微觀瑕疵的預測），然後分別將它們導入各自的模型進行推理。最終的預測結果將涵蓋圖像中的兩種瑕疵類型，一組圖片檢測時間約為 2 秒。以下為兩組圖片的檢測範例，前七張為宏觀檢測，後三張為微觀檢

測，如圖 6.11、6.13 所示，檢測結果如圖 6.12、6.14。

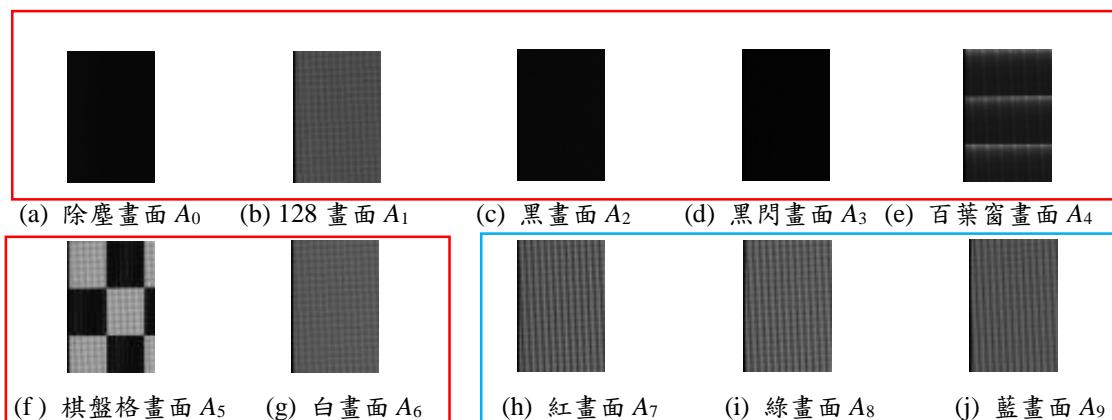


圖 6.11、圖編號 03029

```
文件 npy\03029.npy 的圖像形狀: (60, 40, 10)
前7張圖片形狀: (1, 60, 40, 7)
後3張圖片形狀: (1, 60, 40, 3)
1/1 ━━━━━━ 1s 1s/step
宏觀預測結果: [0]
1/1 ━━━━━━ 1s 946ms/step
微觀預測結果: [0]
```

圖 6.12、03029 檢測結果

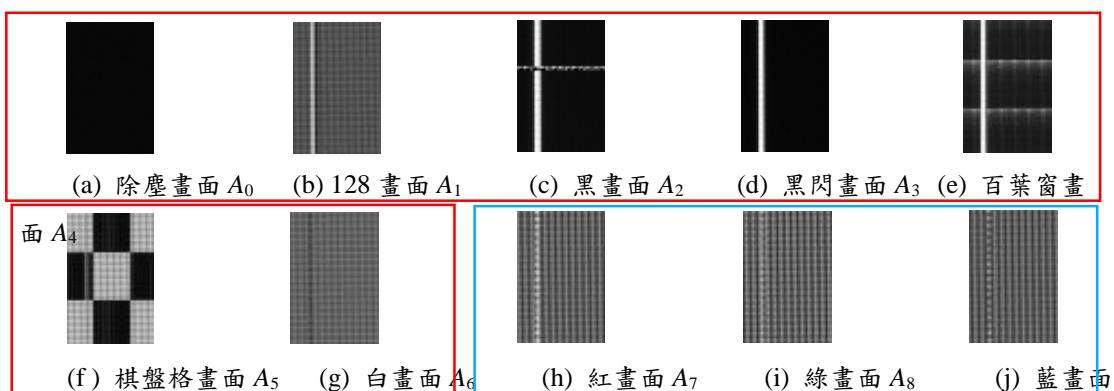


圖 6.13、圖編號 13107

```
文件 npy\13107.npy 的圖像形狀: (60, 40, 10)
前7張圖片形狀: (1, 60, 40, 7)
後3張圖片形狀: (1, 60, 40, 3)
1/1 ━━━━━━ 1s 1s/step
宏觀預測結果: [1]
1/1 ━━━━━━ 1s 948ms/step
微觀預測結果: [1]
```

圖 6.14、13107 檢測結果

第七章 結論與未來方向

7.1 結論

在現今科技快速發展的時代，尤其是在製造業領域，品質控制與產品檢測的需求日益突顯。對於小尺寸 TFT-LCD 電路的檢測，特別是對於可能存在的瑕疵進行準確的定位與分類。本研究將完成基於影像處理技術與人工智慧算法的解決方案，旨在開發一個能夠自動檢測、定位並分類小尺寸 TFT-LCD 電路瑕疵的系統。該系統將整合單一攝影機、影像處理技術以及多重 CNN 網路的集成技術，並符合 ISO/TR 9241-310 標準，以實現對 TFT-LCD 顯示器電路瑕疵的高精準檢測，為製造業提供可靠的品質控制解決方案。

- (1). 開發利用小尺寸 TFT-LCD 電路顯示功能，由單一攝影機取得能分辨不同類型瑕疵的特徵影像，利於瑕疵的定位與分類。
- (2). 利用影像處理技術，自動偵測與定位小尺寸 TFT-LCD 電路檢測區域，清除目標區域外的環境干擾。
- (3). 應用多重 CNN 網路的集成技術，處理現行與區域型的 mura 類型瑕疵，達成自動化的高精準瑕疵定位與類型識別。
- (4). 依據 ISO/TR 9241-310 標準，能對 TFT-LCD 顯示器電路的次像素進行瑕疵類型、位置與數量的檢測。

7.2 討論

本研究在小尺寸 TFT-LCD 電路瑕疵檢測方面取得了顯著進展，但仍存在一些待解決的問題。

微觀瑕疵模型精度不足仍是一個挑戰。儘管採用了 CNN 模型但對於極細微的缺陷，如微小線條或輕微色差，現有模型的識別準確率仍有提升空間。這可能源於微觀瑕疵樣本不足或模型結構對微觀特徵的捕捉能力有限。模型預測速度不夠快也是一個顯著問題。在高速生產環境中，處理高解析度圖像或多任務檢測時的延遲可能無法滿足實際需求，影響生產效率。

系統的適應性和泛化能力也值得關注。當前模型可能在特定條件下表現良好，但面對不同尺寸、型號的 TFT-LCD 或變化的生產環境時，其性能可能會受到影響。系統的長期穩定性和維護成本也需要考慮。在長期運行過程中，模型性能可能會因為生產條件的微小變化而逐漸下降，如何實現模型的自適應更新和高效維護是一個重要課題。解決這些問題將有助於進一步提升系統的實用性和可靠性，使其更好地滿足要求。

7.3 未來方向

本研究將使用到很多電腦視覺、影像處理、機器學習與深度學習方

面的技術，例如：

- (1) 應用深度學習模型的瑕疵特徵擷取與分類，涉及多重 CNN 網路的集成模型設計與訓練。
- (2) 利用改良型 U-Net 進行語意分割的像素級瑕疵定位與辨識等。
- (3) 進一步提升微觀瑕疵的模型質量，提高預測與驗證準確率。

參考文獻

- [1] K. Nakashima, "Hybrid inspection system for LCD color filter panels," in *Proceedings of the 10th Anniversary (IMTC/94), Advanced Technologies in I & M, 1994 IEEE Instrumentation and Measurement Technology Conference*, 1994, pp. 689–692.
- [2] Y. C. Chang, K. H. Chang, H. M. Meng, and H. C. Chiu, "A novel multicategory defect detection method based on the convolutional neural network method for TFT-LCD panels," *Mathematical Problems in Engineering*, vol. 2022, article 6505372, pp. 1-14.
- [3] W. Ming, S. Zhang, X. Liu, K Liu, J. Yuan, Z. Xie, and X. Guo, "Survey of mura defect detection in liquid crystal displays based on machine vision," *Crystals*, vol. 11, no. 12, article 1444, 2021, pp. 1-14.
- [4] M. Chen, P. Chen, S. Wang, Y. Cui, Y. Zhang, and S. Chen, "TFT-LCD mura defect visual inspection method in multiple backgrounds," *Journal of the Society for Information Display*, vol. 30, no. 11, 2022, 818-831.
- [5] H. P. Lu and C. T. Su, "CNNs combined with a conditional GAN for mura defect classification in TFT-LCDs," *IEEE Transactions on*

Semiconductor Manufacturing, vol. 34, no. 1, 2021, pp. 25-33.

- [6] ISO 9241-300:2008. Ergonomics of human-system interaction – Part 300: *Introduction to electronic visual display requirements. International Organization for Standardization*, 2008. Available at: <https://www.iso.org/standard/40096.html>
- [7] J. Y. Lee and S. I. Yoo, “Automatic detection of region-mura defect in TFT-LCD,” *IEICE Transactions on Information and Systems*, vol. 87, no. 10, 2004, pp. 2371-2378.
- [8] Y. C. Song, D. H. Choi, and K. H. Park, “Multiscale detection of defect in thin film transistor liquid crystal display panel,” *Jpn. J. Appl. Phys.*, vol. 43, 2004, pp. 5465–5468.
- [9] D. M. Tsai, P. C. Lin, and C. J. Lu, “An independent component analysis-based filter design for defect detection in low-contrast surface images,” *Pattern Recognition*, vol. 39, 2006, pp. 1679-1694.
- [10] S. S. Fan and Y. Chuang, “Automatic detection of mura defect in TFT-LCD based on regression diagnostics,” *Pattern Recognition Letters*, vol. 31, 2010, pp. 2397–2404.
- [11] W. Pratt, S. S. Sawkar, and K. R. Reilly, “Automatic blemish detection in liquid crystal flat panel displays,” in *Proceedings of the*

Machine Vision Applications in Industrial Inspection VI, January 1998;
vol. 3306, pp. 25-30.

- [12] C. Li, X. Zhang, Y. Huang, C. Tang, and S. Fatikow, "A novel algorithm for defect extraction and classification of mobile phone screen based on machine vision," *Computers & Industrial Engineering*, vol. 146, article 106530, 2020, pp. 1-14.
- [13] C. Jian, J. Gao, and Y. Ao, "Automatic surface defect detection for mobile phone screen glass based on machine vision," *Applied Soft Computing*, vol. 52, 2017, pp. 348-358.
- [14] C. Tan, F. Sun, T. Kong, W. Zhang, C. Yang, and C. Liu, "A survey on deep transfer learning," in *Proceedings 27th International Conference on Artificial Neural Networks and Machine Learning–ICANN*, Oct. 2018, pp. 270-279.
- [15] F. Yu, X. Xiu, and Y. Li, "A survey on deep transfer learning and beyond," *Mathematics*, vol. 10, no. 19, article 3619, 2022, pp. 1-27.
- [16] Y. Guo, H. Shi, A. Kumar, K. Grauman, T. Rosing, and R. S. Feris, "SpotTune: Transfer learning through adaptive fine-tuning," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 4805-4814.
- [17] R. Zhang, H. Tao, L. Wu, and Y. Guan, "Transfer learning with

neural networks for bearing fault diagnosis in changing working conditions," *IEEE Access*, vol. 5, 2017, pp. 14347-14357.

- [18] J. Margeta, A. Criminisi, R. C. Lozoya, D. C. Lee, and N. Ayache, "Fine-tuned convolutional neural nets for cardiac MRI acquisition plane recognition," *Comput. Methods Biomed. Eng. Imag. Visual.*, vol. 5, no. 5, 2016, pp. 339-349.
- [19] B. Xiao, Y. Liu, and B. Xiao, "Accurate state-of-charge estimation approach for lithium-ion batteries by gated recurrent unit with ensemble optimizer," *IEEE Access*, vol. 7, 2019, pp. 54192–54202.