

小尺寸TFT-LCD顯示器電路瑕疵偵測與辨識系統的研究與開發

(一) 計畫摘要

TFT-LCD顯示器電路瑕疵偵測與辨識面臨的挑戰，主要源於瑕疵的多樣性和微觀尺度。本研究針對小尺寸TFT-LCD顯示器電路，提出了一套綜合解決方案以應對這些挑戰。首先，本研究應用了影像疊加、聯通物件標籤和形態學等影像處理技術，有效地實現了電路範圍內多個非電路物件的自動識別與隔離，從而為更精確的瑕疵偵測奠定了基礎。進一步地，本研究將瑕疵分為宏觀與微觀兩大類，並採用不同的模式進行偵測與分類。在宏觀瑕疵的辨識上，採用了預訓練集成網路方法，利用從製造商生產線獲取的真實數據來提取精確的信息。這種方法不僅提高了對新型瑕疵的識別能力，同時也提升了系統的靈活性與準確性。對於微觀瑕疵的檢測與識別，本研究結合了注意力機制的改良型U-Net，對每個像素進行語義分割處理，實現了更高準確度的瑕疵類別識別。這種方法不僅提升了檢測的靈敏度，同時能夠適應不斷變化的檢測需求。面對只能獲得少量樣本特徵影像的情況，本研究應用ADASYN演算法來處理正常電路與包含瑕疵樣本之間的不平衡問題。綜合上述，本研究所規劃的方法不僅提高了TFT-LCD電路瑕疵偵測與辨識的效率和準確性，同時為未來相關研究提供了寶貴的參考和啟示。

關鍵詞：瑕疵偵測、瑕疵辨識、微觀瑕疵、小尺寸TFT-LCD電路

(二) 計畫研究動機與研究問題

2.1 研究動機

在現代顯示技術製造領域中，TFT-LCD顯示器電路瑕疵的偵測與分類具有極其重要的地位。首先，這是一種關鍵的品質控制手段，它確保TFT-LCD顯示器能夠達到高品質的標準。在生產過程中，瑕疵的偵測與分類使我們能夠及時識別並排除不合格品，從而保障了最終產品的品質。此外，有效的瑕疵偵測不僅有助於減少因品質問題而產生的退貨和廢品，從而降低生產成本，而且還能提升客戶的滿意度，對於品牌形象和市場競爭力的提升也具有顯著的正面效應。

TFT-LCD顯示器的應用範圍極為廣泛，根據其尺寸可以分為小尺寸、中尺寸及大尺寸三大類型。小尺寸TFT-LCD顯示器，通常是指對角線長度小於10英寸的顯示器；這類顯示器主要被應用於手持和攜帶式設備，例如智慧手機、可穿戴設備和數位相機等。中尺寸TFT-LCD顯示器的對角線長度一般介於10英寸到30英寸之間；它們經常被使用於個人電腦、筆記型電腦、小型電視和車載顯示系統等領域。至於大尺寸TFT-LCD顯示器，則是指對角線長度超過30英寸的顯示器；這一類型的顯示器主要用於大型電視、公共顯示屏幕以及專業級顯示器，如會議室或廣告用顯示器等。根據歷年的統計數據，這三種尺寸類型的顯示器在產能與應用範圍上均維持了一定的市場占比，保持著各自製造產業的高需求。特別是小尺寸顯示器，由於較早形成產業鏈，在生產技術上較為成熟。然而，在引入新型生產技術和瑕疵檢測技術方面，進展相對較為緩慢和落後。本研究旨在針對小尺寸TFT-LCD顯示器電路瑕疵，提出更為有效的檢測與辨識技術，以降低誤判率，進而提升產品的整體價值。

TFT-LCD顯示器電路瑕疵偵測與辨識是一項具有高度挑戰性的工作。首先，這些瑕疵的類型相當多樣，依照單張感測影像能被觀察的程度，大致可劃分為宏觀瑕疵和微觀瑕疵兩大類[1, 2]。宏觀瑕疵主要包括那些能夠輕易被肉眼察覺的瑕疵，如Mura(光亮不均勻)、光洩漏、閃頻等；而像素點發光不良、黑白光點及刮痕、灰塵微粒等由於其尺寸較小，則被劃分為微觀瑕疵。然而，

大多數關於TFT-LCD顯示器電路瑕疵檢測的研究重點主要集中在宏觀瑕疵上，尤其是Mura[3-5]。另一方面，整個電路影像掃描的像素可能達到數億個，而某些瑕疵僅涉及2-3個像素。因此，一個優質的TFT-LCD顯示器電路瑕疵偵測與辨識系統需要解決瑕疵偵測與辨識的多樣性問題、提升辨識準確性，同時降低計算複雜度，以提高執行速度。

基於以上的論述，本研究將著重於針對小尺寸TFT-LCD顯示器電路的多類型瑕疵偵測與辨識技術研究與開發。相較於中大尺寸的TFT-LCD顯示器電路，小尺寸TFT-LCD顯示器電路在檢測執行上具備以下特色：

- (1) 複雜的影像感測環境：在一個影像感測過程中，可能同時包含多個電路的影像，這意味著檢測影像中可能包括檢測設備的其他組件，而非僅是電路的某一局部區域。
- (2) 高度同質性與規律性：與一般的積體電路(IC)相比，TFT-LCD顯示器電路是由以像素為基礎的大型陣列組成，其具有顯著的同質性和規律性。
- (3) 主動發光的能力：TFT-LCD顯示器能主動發光，因此在檢測時可以通過顯示不同內容來使瑕疵在不同的特徵影像中顯現，這與傳統固定電路的檢測對象存在顯著差異。
- (4) 亮度分布的變化：由於背光或LCD本身的瑕疵，TFT-LCD顯示器可能產生不同的亮度分布，使得瑕疵的成像變化較大。

這些特性意味著對小尺寸TFT-LCD顯示器電路進行瑕疵檢測與分類所需的技術，與用於中大尺寸TFT-LCD顯示器電路的方法存在顯著差異，需要解決不同的技術問題。

2.2 研究問題

本研究針對小尺寸TFT-LCD電路進行其瑕疵偵測與辨識的系統研發。基於前述的實務需求，預期中的研究問題與解決方案說明如下：

- (1) **檢測區域定位**：不像大尺寸電路是以掃描方式進行局部區域的檢測，因此不會有電路以外的物件出現在檢測區域內。而小尺寸電路則是能同時觀看到數個電路，因此會觀察到電路間的置具、檢測設備與背景等非電路的物件，需要加以遮蔽，以免干擾瑕疵的偵測與辨識。本研究將應用影像疊加、聯通物件標籤、形態學等影像處理技術，自動完成一個感測區域內多個電路範圍的定位任務。
- (2) **宏觀瑕疵類型辨識**：傳統方法在處理多樣瑕疵辨識時，可能需要手動設計多個規則或過濾器，且對於新的瑕疵類型難以適應，使得整個辨識系統不夠靈活。本研究規劃採用深度學習方法，直接由製造商生產線取得的真實數據中，訓練集成式深度模型，達成自動化的高精準瑕疵定位與類型識別。
- (3) **微觀瑕疵檢測與識別**：針對ISO/TR 9241-310標準[6]的微觀次像素瑕疵檢測，傳統方法需要複雜的手動設置，且準確度受限於先前定義的檢測模型，難以應對不斷變化的檢測需求。本研究為每個像素產生多重特徵，再藉由這些特徵分布，以語意分割的檢測方式，訓練結合注意力機制的改良式U-Net，進行像素級的瑕疵類別識別與標註。

(三) 文獻回顧與探討

3.1 檢測區域定位

由於小尺寸TFT-LCD顯示器電路的成像面積相對較小，這使得在一次感測程序中可以包含多個電路，從而提高生產和檢測的速度。然而，這種方法的一個挑戰是，在非電路區域也可能包含了生產和檢測環境中的置物、驅動電路和檢測平台，這就導致了在偵測前需要獲得特定的偵測

遮罩(detection mask)。在此背景下，Li等人[7]基於電腦視覺技術，通過邊緣檢測和閾值分割，進行基於形狀的模板匹配以確定感興趣的區域(ROI)。然而，這種方法主要針對影像中的單一電路有效。Jian等人[8]則採用形態學中的開運算去除雜訊，並使用Otsu法則來獲得電路區域的二值影像。隨後，他們利用邊緣檢測算子從二值影像中提取出圖案輪廓。由於不變量僅依賴於物體的幾何形狀，因此即使在物體位移和旋轉的情況下，它們也能保持不變。顯然，這些方法仍然局限於單一電路的偵測遮罩求取，對於複數電路的情況仍然存在不同方法開發的需求。

3.2 瑕疵類型偵測與辨識

本研究著重於TFT-LCD顯示器電路中瑕疵的偵測與辨識，其中尤以Mura瑕疵為主要研究對象[3, 9]。在日語中，“Mura”一詞意指“不均勻”或“斑點”，專門用來描述TFT-LCD顯示器中的一種特殊瑕疵。Mura瑕疵表現為液晶顯示器上亮度或色彩不均勻的區域，這些不均勻現象通常源於製造過程的不一致性或材料瑕疵。這類瑕疵會在顯示器上形成斑點、條紋或雲狀的暗區或亮區，進而影響顯示器的整體視覺效果。

Mura瑕疵一般分為點瑕疵、線瑕疵和區域瑕疵三種類型[10, 11]，它們主要根據外觀特徵和形狀進行區分，每種瑕疵類型可能需要不同的檢測和分類方法。隨著LCD技術的發展，Mura瑕疵的出現機率也在增加。因此，檢測Mura瑕疵是一項具有挑戰性的任務，可以從以下幾個方面來證明：(1) Mura瑕疵通常出現在亮度不均且對比度低的局部區域[12]，因此在變化的光照條件下尤其難以識別；(2) Mura瑕疵沒有固定的大小和規則的形狀，使得同一類型的瑕疵表現出較大的差異，而不同類型的瑕疵可能表現出較小的差異，容易導致誤分類[13]；(3) 一些Mura故障的樣本相對較為罕見，這導致識別系統中樣本數據的嚴重不平衡，增加了識別Mura瑕疵的難度。

用於TFT-LCD顯示器電路的Mura瑕疵分類主要可分為三種類型的分類器。

- (1) 基於傳統機器視覺與影像處理技術的瑕疵分類器：是機器視覺技術在智慧製造領域的關鍵應用之一，已成為取代人工視覺檢測的有效方式[14]。機器視覺是一種利用光學設備和非接觸式感測器自動接收和處理真實物體影像的系統，該系統主要通過Mura瑕疵的空間大小、平均亮度、面積、重心位置和形狀參數等因素來區分和分類Mura瑕疵[15-18]。Xie等人[19]針對顯示器線瑕疵的檢測提出了一種基於顏色特徵融合的方法，以提高對低對比度線瑕疵的偵測精度。他們使用相對熵最大準則從RG|GR和BY|YB通道獲得顏色顯著性通道，然後通過RG|GR與a通道、BY|YB與b通道的組合來計算紅綠和藍黃顏色融合圖。最後，根據融合顏色顯著圖的平均值和標準差計算分割閾值，並將融合的顏色顯著圖二值化和分割以獲得彩色線瑕疵的二值圖。此外，Xie等人[20]還提出了一種基於RGB通道的顯著顏色通道頻域濾波技術，用於串擾瑕疵的檢測。Wang[21]則採用Lab色彩空間，提出了一種基於通道對比度敏感度函數濾波的彩色Mura瑕疵檢測方法，基於L通道和ab通道的融合特徵圖的自適應分割閾值實現。這些方法使用RGB攝影機進行電路顯示畫面的感測，受環境照明的影響較大，但未充分利用顯示器具有展示特徵影像的優勢。
- (2) 基於傳統機器學習技術的瑕疵分類器：這類方法通過選擇合適的感測影像特徵，建立並訓練機器學習模型，以達到準確評估或識別瑕疵類別的目的。為了識別影像中的瑕疵類型，所選取的特徵必須能夠準確描述影像，同時能夠有效區分不同類型的影像。瑕疵分類的關鍵任務是利用提取出的特徵集來訓練分類器，使其能在監督或無監督模式下正確識別各類表面瑕疵。在監督模式識別中，支援向量機(SVM)[22-24]、K最近鄰(KNN)[25-27]、隨機森林[28]等算法

是典型的代表。KNN 演算法因其簡單性和穩定性而廣受青睞。Mustaqeem 與 Saqib[23]提出了一種將主成分分析(PCA)與支援向量機(SVM)相結合的混合機器學習方法，以更準確地預測瑕疪並降低時間和空間複雜度。Yildiz 等人[27]則運用了一系列預處理技術，如小波變換、閾值和病理操作，來準備用於瑕疪檢測的影像。接著，利用灰階共生矩陣方法提取特徵，再應用 KNN 演算法對瑕疪影像進行分類。Torres 等人[28]則提出了一種基於直方圖相似性和隨機森林演算法的方法，用於自動檢測 LCD 顯示器上的 Mura 瑕疪。他們建立了一個包含多種 Mura 瑕疪類型的資料庫，共計 7000 多張影像，以訓練模型。實驗結果顯示，所提方法具有高達 99% 的準確度，並將每張影像的處理響應時間縮短至 27 毫秒，使其適用於工業應用。

- (3) 基於深度學習模型的瑕疪分類器，主要以卷積神經網路 (CNN) 為核心演算法。近年來，隨著計算能力的提升和大數據的興起，以及機器透過增加網路層數自動從資料中學習的深度學習技術，已在工業生產中取得顯著成效。深度學習方法能自動提取和組合物體的本質特徵資訊，特別適用於影像分類。CNN 是目前最常用於影像分類的架構之一，其最初設計目的即是為了影像分析，使其非常適用於視覺檢測中的自動瑕疪分類[29]。深度學習已被廣泛應用於包括工業生產和電子元件在內的各種工業瑕疪分類領域。Lin 等人[30]提出了一種結合視覺注意機制和特徵映射的深度學習穩健偵測方法，透過 X 射線檢測來識別瑕疪。該方法利用 CNN 從潛在瑕疪區域提取特徵，以獲得深度學習特徵向量，並用此向量計算可疑瑕疪區域的相似度，有效解決了誤檢和漏檢的問題。Nguyen 等人[31]提出了一種基於 CNN 的檢測系統，用於鑄造產品的瑕疪分類。然而，CNN 深度學習模型的效能主要依賴於大量高品質資料。Kim 等人[32]則提出了一種先進行正確電路圖案與瑕疪區域分割的預處理步驟，利用指標區分瑕疪和背景區域，該指標對亮度變化和微小雜訊具有較高的穩健性。透過此指標，可以獲得有用的瑕疪資訊，同時消除背景圖案的干擾。當結合各種影像預處理資訊後，所提出的具有堆疊整合技術的卷積神經網路在提高瑕疪分類性能方面更為有效。

3.3 微觀瑕疪檢測與識別

微觀瑕疪亦被稱作次像素瑕疪，其特點在於位於一個完整像素中的紅、綠、藍三種子像素的異常[33-37]。次像素瑕疪涉及這些子像素中任何一種出現的問題。因此，顯示的瑕疪類型可能包括以下幾種：(1) 全暗像素：指像素處於持續的黑色狀態。(2) 全亮像素：像素持續亮著，無法關閉。(3) 色偏向素：像素無法正確顯示預定的顏色。這類瑕疪對整體顯示質量的影響可能相對較小，但在對高解析度和高畫質有較高要求的應用中，這些瑕疪可能變得更加顯著。因此，瑕疪檢測的目標在於能夠準確地檢測出每個子像素是否正常運作。在檢測過程中，由於次像素的尺寸非常微小，所以需要高解析度的檢測設備來識別這些細微的像素級瑕疪。此外，檢測過程還應兼顧處理速度與效率，以符合大規模生產的要求。

(四) 研究方法及步驟

4.1 檢測瑕疪分類

LCD 面板的生產過程極為複雜，涵蓋了多個精密製造階段。在此過程中，可能出現各種瑕疪，這些瑕疪會影響產品的性能和品質。一些常見的瑕疪類別及其可能的生成原因包括：

- (1) 點型瑕疪：此類型包括亮點、暗點及顏色異常點等，其生成原因可能源於塵埃、污垢或製造過程中材料的雜質。這些瑕疪在顯示外觀上，由於像素中三個 LCD 單元各自的瑕疪和組合而形成的次像素瑕疪，需要在微觀層次進行細緻的識別。

- (2) 線型瑕疵：包括垂直線和水平線等類型，其產生原因可能為源線或闇線的瑕疵或損壞。這些瑕疵可能由物理損傷、製程不良或材料問題導致，並對顯示器的視覺效果造成顯著影響。
- (3) 區域型瑕疵：此類瑕疵為液晶顯示器中常見的畫面品質問題，主要表現為顯示幕某一區域內的亮度或色彩不均勻。瑕疵類型包括黑漏光、色彩偏差、亮度不均勻等，其產生原因可能是液晶分佈不均、材料老化或壓力不均等導致的液晶或光學層性能異常。在外觀上，這些瑕疵在形狀和大小上可能呈現極大的變化，從小塊斑點到大片區域均有可能出現。此外，區域型Mura瑕疵的分佈通常是隨機的，可能出現在屏幕的任何位置。

本研究針對這三種瑕疵進行檢測與辨識，其中點型瑕疵屬於微觀瑕疵，而線型與區域型瑕疵則屬於宏觀瑕疵，可透過肉眼直接觀察。這兩種瑕疵在識別方法與特徵資訊上具有明顯差異，故本研究將瑕疵檢測與辨識任務分別透過不同的深度學習網路來完成，整體的瑕疵檢測與辨識流程如圖1所示，各個處理單元將分述如下。

4.2 檢測樣本的特徵影像

為了能夠有效地檢測並識別顯示器上的各種可能瑕疵，透過同一台攝影機加上驅動電路控制，就能產生顯示器的多張特徵影像，對於顯露不同類型的瑕疵極為有效。這些特徵影像能夠從不同的角度和條件下展示待檢測樣本的顯示特性，使各種潛在的瑕疵被清楚地顯示出來。多張特徵影像重要性的幾個關鍵點包括：

- (1) **不同顯示條件下的瑕疵顯示**：不同的顯示條件(如亮度、對比度、顏色設置等)可能會使某些瑕疵更加明顯。例如，一個點型或區域型瑕疵在高亮度下可能很難被發現，但在低亮度或特定顏色設置下可能變得非常顯著。
- (2) **全面的瑕疵檢測**：通過多張特徵影像，可以從不同的視角和環境設置中檢測瑕疵，從而提高檢測的全面性和準確性。
- (3) **增加數據豐富性**：多張特徵影像提供了更多的數據，這對於使用深度學習或其他數據驅動的方法來檢測瑕疵非常重要，因為這些方法依賴於大量的數據來訓練和改進其識別模型。
- (4) **特定瑕疵類型的識別**：某些特定類型的瑕疵可能只有在特定的顯示條件下才能被識別出來。例如，一些色彩相關的點型瑕疵可能只有在展示特定顏色範圍時才會出現。

基於上述的考量，本研究將使用多張特徵影像，以增強瑕疵檢測的效率和準確性，還可以確保對各種可能的瑕疵類型進行全面的檢測，從而提高整體顯示品質。規劃對每一個樣本使用的10種特徵影像，如圖2所示，各特徵影像的設計原則說明如下：

- (1) 除塵畫面 I_0 ：由於面板表面會存在灰塵顆粒，不能將這些顆粒視為瑕疵。在不點亮LCD面板

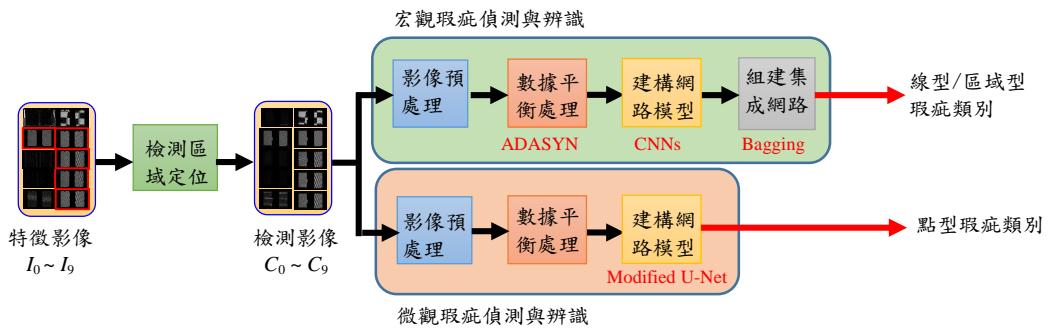


圖1、整體的瑕疵檢測與辨識流程

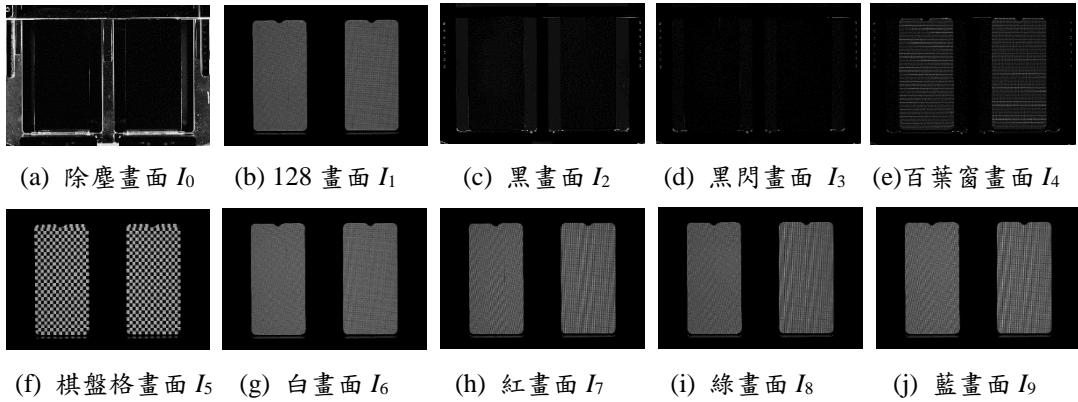


圖2、每一個檢驗樣本使用的10張特徵影像

時(全黑畫面)，可在影像上找到白點的灰塵顆粒，需要將其遮罩為非瑕疵。

- (2) 128畫面 I_1 ：以灰階皆為128的影像顯示，可以取得無法點亮或永遠點亮的像素位置。
- (3) 黑畫面 I_2 ：以灰階皆為0的影像顯示，可以取得永遠點亮的像素位置。
- (4) 黑閃畫面 I_3 ：以低於60 Hz的頻率，顯示黑畫面。用以觀察在低頻時，LCD漏電的情況(無法高速顯示黑色)。
- (5) 百葉窗畫面 I_4 ：以百葉窗影像顯示(每個帶狀圖形的灰階由255至0均勻分布)，觀察觸控區域(方格區域)的短路現象，同時監看四周觸控區域的互動狀況(充放電影響)。
- (6) 棋盤格畫面 I_5 ：以棋盤格影像顯示(灰階分別為255(白色)與0(黑色)的方格間錯分布，大小同觸控區域)，觀察觸控區域(方格區域)的短路現象，若發生就會在影像中顯示較淡的顏色。
- (7) 白畫面 I_6 ：以灰階皆為255的影像顯示，可以取得永遠無法點亮的像素位置(可能是R/G/B點之一)。
- (8) 紅畫面 I_7 ：以紅色影像顯示，可以取得永遠無法點亮紅點的像素位置。
- (9) 綠畫面 I_8 ：以綠色影像顯示，可以取得永遠無法點亮綠點的像素位置。
- (10) 藍畫面 I_9 ：以藍色影像顯示，可以取得永遠無法點亮藍點的像素位置。

4.3 檢測區域定位

針對小型TFT-LCD顯示器電路影像，常見的挑戰之一是一張影像中會存在多個顯示器電路，並有許多電路以外的背景元件。在此情形下，有必要將影像的前景區域(即電路部分)與背景區域進行有效分割。這一步驟對於精準定位檢測區域並排除非目標區域的干擾至關重要，尤其是在瑕疵檢測和識別過程中。整個檢測區域定位的處理流程如圖3所示。考慮到每個樣本包含10張特徵影像(分別標記為 I_0 至 I_9)，在分析這些特徵影像時，特別關注於那些能呈現較為完整且亮度一致的前景區域之特徵影像。此外，因為使用相同的攝影機對不同的顯示畫面取像，不存在TFT-LCD顯示器電路的幾何或投影變化。基於此，選擇以 I_1 、 I_6 、 I_7 、 I_8 和 I_9 這幾張特徵影像進行疊加處理，以此獲得更加清晰和集中的前景資訊，從而為後續的分析和處理提供更穩定、可靠的基礎。通過這種方法，可以更準確地識別和定位影像中的電路關鍵區域，為瑕疵檢測提供了必要的影像預處理步驟。

$$I_S = \frac{1}{4.5} \sum_{j=1,6,7,8,9} I_j \quad (1)$$

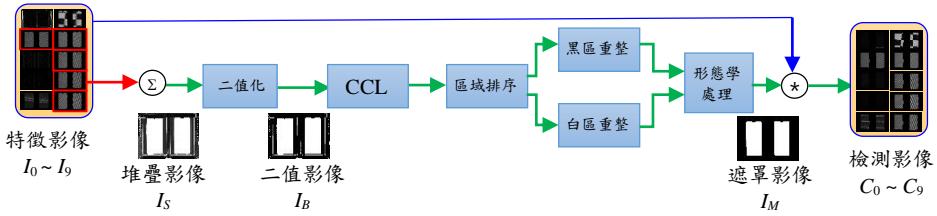


圖3、檢測區域定位處理流程

透過此方式，電路區域在疊加後呈現出相對較高的亮度，而背景區域的亮度則相對被壓抑。這種亮度的對比增強，為後續的影像處理奠定了基礎。當進行二值化處理時，電路區域因亮度較高而轉變為白色，背景區域則因亮度較低而呈現為黑色。此方法有效地區分了電路與背景，從而在二值化影像中清晰地突出了電路區域。這一步驟對於精確識別和定位電路中的特定元件及潛在瑕疵至關重要，進而為瑕疵檢測與辨識提供了清晰且可靠的視覺基礎。

$$I_B = \begin{cases} 255, & I_S > t_B \\ 0, & I_S \leq t_B \end{cases} \quad (2)$$

然而，值得注意的是，在前景的電路區域中，瑕疵像素通常以黑色呈現，而背景區域中的雜訊與製造過程中的痕跡，則在二值化影像中以白色顯示。為了精確獲得完整且正確的前景與背景區分，首先對二值化影像 I_B 分別進行白色區域與黑色區域的聯通元件標籤處理(Connected Components Labeling, CCL)，接著根據面積大小對這些區域進行排序，從而得到白色區域集合 $W=\{w_1, w_2, \dots, w_m\}$ 以及黑色區域集合 $B=\{b_1, b_2, \dots, b_n\}$ ，其中 m 與 n 分別為影像 I_B 中的白色區域與黑色區域數量。

在目前處理的特徵影像中，白色區域主要包含兩個電路區域，其他較小的白色區域則大多為背景中的雜訊。因此，針對集合 W 進行重整，僅保留 w_1 與 w_2 作為電路區域，將 I_B 中屬於 w_3 至 w_m 的其他像素由白色改為黑色，以排除非目標區域的干擾。同理，黑色區域代表背景，但其中較小的黑色區域可能為電路中的瑕疵或機台上的置具或驅動電路。因此，對集合 B 進行重整，保留最大的黑色區域 b_1 作為背景，而將在 I_B 中屬於 b_2 至 b_n 的其他像素由黑色改為白色。此過程確保了電路與背景的有效分離，並為後續瑕疵檢測提供了清晰且準確的基礎。

為了確保前景電路區域的完整性與連續性，本研究在重整後的影像上進行了形態學中的閉運算(Close)。此操作目的在於填補前景電路區域內的小孔洞和斷裂，同時平滑化邊界，而不對物體的總面積造成顯著變化。這一步驟對於確保電路區域的結構完整性和視覺清晰度極為關鍵。

經閉運算處理後的結果影像被定義為遮罩影像 I_M 。隨後，將10張特徵影像(I_0 至 I_9)分別與遮罩影像 I_M 進行點乘運算，從而得到10張專用於檢測的影像(C_0 至 C_9)。

$$C_j = I_j \odot I_M, \quad j=0, \dots, 9 \quad (3)$$

圖4顯示以 I_0 與 I_5 為例的處理程序說明。 I_0 為除塵畫面，在不點亮LCD面板時為全黑畫面，只

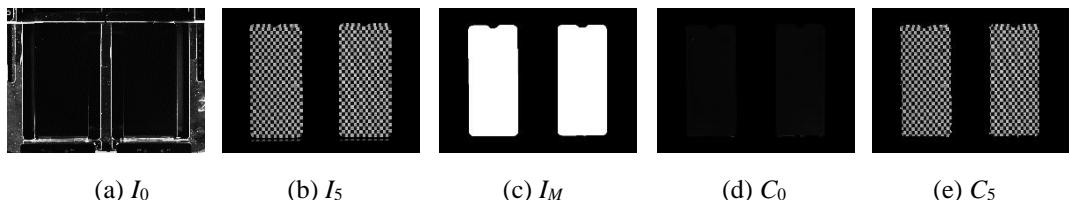


圖4、檢測區域定位處理說明

關注於電路區域的白點顆粒； I_5 為棋盤格畫面，在底部有驅動影像顯示的外部裝置，在檢測時需要加以排除，而透過遮罩處理後的 C_5 則已被刪除。

這一過程確保了所得到的檢測影像僅包含電路區域，從而有效排除了非目標區域的干擾。這些經過篩選和加工的影像成為了後續瑕疵檢測和分析的基礎，確保了分析的準確性和可靠性。通過這樣的處理，可以更集中地關注電路區域的潛在瑕疵，從而提高檢測的效率和精確度。

4.3 宏觀瑕疵檢測與識別

對於瑕疵檢測的任務而言，皆屬於瑕疵的偵測與辨識處理，但由於宏觀瑕疵與微觀瑕疵在本質上與使用資訊上的差異，本研究將這兩類的瑕疵分別處理，以獲取低複雜度與高效能的分類器。

針對超過一個像素點尺寸的線瑕疵與mura瑕疵，本研究將其視為一項針對8個瑕疵類別的辨識任務。用於訓練的影像資料來自於某TFT-LCD製造商，每張影像均包含兩塊小尺寸的TFT-LCD電路，合計涵蓋200個樣本，每個樣本均含有10張具有特徵的影像。此外，經由檢測系統與人工標註的預處理程序，已對存在的瑕疵進行標識。然而，鑑於目前瑕疵標註的方式過於簡略且缺乏精確定位，因此本研究將根據先前的標註，進行重新標註以提供更為明確的表示。

整體偵測與辨識流程規劃如下：

- (1) **影像預處理**：鑑於樣本特徵影像的尺寸高達 $9,344 \times 7,000$ 個像素，對於深度學習模型而言，過大的輸入影像可能導致記憶體不足及模型訓練的困難。考慮到宏觀瑕疵具有不同的尺寸與外型，本研究基於計算設備的硬體限制，將特徵影像分割為多個較小的子影像，旨在透過縮減影像尺寸以縮短模型的訓練時間。由此，每一個子影像將成為一個被檢測的單元，並獲得其分類的輸出標註。
- (2) **數據平衡處理**：在瑕疵檢測任務中，存在有瑕疵的影像數量遠少於無瑕疵影像數量的現象，從而導致數據不平衡。若直接使用原始特徵影像進行模型訓練，模型可能會將所有像素歸類為無瑕疵，造成總體分類準確率高，但對少數類別(含瑕疵者)的驗證準確率偏低，導致模型實用性降低。針對不平衡數據集的解決方案之一是對少數類別進行過採樣(oversampling)，即複製少數類別樣本，但此舉不會為模型提供新訊息。相反的，從現有樣本中合成新樣本是一種針對少數類別的數據增強(data augmentation)方法，稱為合成少數類過採樣技術(Synthetic Minority Oversampling Technique, SMOTE)[38]。本研究擬採用SMOTE類演算法中的自適應合成採樣(Adaptive Synthetic Sampling, ADASYN)演算法[39]，其基本原理包括初步確定數據集中的少數類樣本，計算樣本不平衡程度，即針對每個少數類別樣本計算其鄰近區域內多數類別樣本(DF類別)與少數類樣本的比例。進一步根據每個少數類別樣本周圍的多數類別樣本密集程度決定合成樣本數量，少數類別樣本周圍多數類別樣本越多，則合成更多樣本。針對每個少數類別樣本，通過在其與鄰近少數類別樣本之間進行隨機插值生成新的合成樣本。
- (3) **構建神經網路**：目前在物件分類領域中最為廣泛應用的神經網路模型是卷積神經網路(CNN)。然而，這類網路模型通常需要依賴大量的訓練數據集來提高其性能；因此，在數據量有限的情況下，直接將CNN應用於Mura瑕疵的分類可能會面臨一定的困難。為了解決這一問題，轉移學習成為一種適宜的選擇。轉移學習是指在一個大型且標籤完善的影像數據集上對CNN進行初始訓練，使其學習到適用於所有影像的通用影像特徵，然後將這些特徵應用於規模較小的數據集中以擷取相關特徵[40, 41]。在轉移學習過程中，整個網路在監督學習的條件下完成訓練後，所得到的特徵提取器可以被進一步訓練或直接重用於特定的應用目的。轉移學習不

僅在分類效果上表現良好，還可以顯著降低對訓練數據量的依賴，從而有效提升模型的適應性和應用範圍。因此，轉移學習解決了在樣本數據有限，且分佈不均的多類別分類問題上使用卷積神經網路(CNN)時遇到的挑戰。接著，對預訓練的CNN進行微調處理。微調是通過反向傳播使用來更新CNN的預訓練權重的過程。對瑕疵影像數據的廣泛研究顯示，微調與從頭開始訓練CNN一樣有效，同時對訓練數據的大小更具強健性[42-44]。

- (4) **組建集成網路**: 本研究旨在進一步發揮小量瑕疵樣本的應用潛力，故引入了集成學習的理念。集成學習透過結合多元的模型與技術，能夠顯著提升整體模型在性能、穩健性與準確性方面的表現，尤其適用於處理樣本量有限的複雜問題。集成學習是機器學習的一種過程，其特點在於將多個分類模型的結果綜合起來，從而獲得更佳的預測效能，形塑出一個高品質的分類器。我們的分類網路整合了經過微調的多重卷積神經網路，從而能夠將從大量影像中學習到的通用特徵更精確地適應於識別不同的瑕疵影像。為此，在對相同數據集訓練了眾多深度CNN之後，我們規劃將這些網路組合成一個集成體，以進一步提高分類的準確度。在本研究中，我們選擇裝袋法(Bagging)作為處理集成學習訓練集的主要方法。裝袋法通過訓練多個基礎CNN分類器來實現，每個分類器均源自於不同的樣本，該樣本是通過對訓練數據集進行有替換的子採樣而獲得，其大小與原訓練數據集相同。在模型聚合的過程中，透過多數投票法將眾多分類器的結果整合，最終由得票數最多的類別作為最終的預測結果。

4.4 微觀瑕疵檢測與識別

在微觀瑕疵檢測的研究範疇內，本研究首先明確界定每個像素所涵蓋的要素：

- (1) 液晶顯示器(LCD)的三原色：紅色(R, Red)、綠色(G, Green)、藍色(B, Blue)；
- (2) 五種不同的輸出狀態：無瑕疵(DF, Defect-Free)、全亮瑕疵(FL, Full-Light)、全暗瑕疵(FD, Full-Dark)、半亮瑕疵(HL, Half-Light)、半暗瑕疵(HD, Half-Dark)。

基於上述定義，共可組合出15種不同的像素狀態。

根據所定義的像素狀態，本研究將其視為一項針對15個類別的辨識任務。用於訓練的影像資料來自於某TFT-LCD製造商，每張影像均包含兩塊小尺寸的TFT-LCD電路，合計涵蓋200個樣本，每個樣本均含有10張具有特徵的影像。此外，經由檢測系統與人工標註的預處理程序，也將同於宏觀瑕疵的辨識流程，根據先前的標註進行重新標註以提供更為明確的表示。

整體偵測與辨識流程規劃如下：

- (1) **數據預處理**：同宏觀瑕疵辨識的處理方式，但在子影像的分割上將趨向於更小的尺寸。
- (2) **數據平衡處理**：同宏觀瑕疵辨識的處理方式。
- (3) **構建神經網路**：在微觀瑕疵檢測的情境中，本研究將其視為一種語意分割的應用。U-Net是一種專為影像分割設計的深度學習網路，由於其卓越的性能，它也被廣泛應用於其他類型的語義分割任務中[45]。U-Net的結構形似字母“U”，包括一個縮減尺寸的編碼器和一個擴張尺寸的解碼器。在編碼器階段，網路學習影像的特徵表示，解碼器階段則將這些特徵轉換成像素級的類別分割影像。此外，外加的跳躍連接(Skip Connections)將編碼器的特徵圖與解碼器的對應層相連接，幫助解碼器更好地重建影像細節。由於跳躍連接的加入，解碼器可以利用來自編碼器的高解析度特徵來進行精確的像素分類。U-Net另一個吸引人的設計，是適合於只有少量數據的情況，因此有利於本研究的目標領域使用。

本研究參考[46]提出的一種基於自監督對比學習的改進U-Net兩階段框架，用於TFT-LCD的瑕

疵像素分割。該框架以改良的U-Net為基本架構，突顯目標瑕疵的顯著特徵。改良的U-Net透過整合典型U-Net架構中的殘差結構和注意力機制進行改進，如圖5所示。此框架包括兩個學習階段：預訓練和微調。在預訓練階段，從未標記的特徵影像中學習潛在的特徵表示。訓練資料中使用瑕疵影像和正常影像，使模型在無監督比較的情況下學習高維向量空間中瑕疵與其正常像素之間可區分的映射關係。在微調階段，網路載入預訓練後的參數，並使用標記的訓練資料進行重新訓練。

- (4) **訓練模型**：本研究將數據分為訓練數據、驗證數據和測試數據。訓練和驗證數據用於構建模型，測試數據用於驗證模型的分類能力。選擇優化器是模型訓練的重要部分，可以用來計算各種梯度。本研究規劃使用Adam作為主要優化器[47]，它可以在防止過擬合方面產生積極影響，並適用於大多數分類問題。

(五) 預期結果

- 開發利用小尺寸TFT-LCD電路顯示功能，由單一攝影機取得能分辨不同類型瑕疵的特徵影像，利於瑕疵的定位與分類。
- 利用影像處理技術，自動偵測與定位小尺寸TFT-LCD電路檢測區域，清除目標區域外的環境干擾。
- 應用多重CNN網路的集成技術，處理現行與區域型的mura類型瑕疵，達成自動化的高精準瑕疵定位與類型識別。
- 依據ISO/TR 9241-310標準，能對TFT-LCD顯示器電路的次像素進行瑕疵類型、位置與數量的檢測。

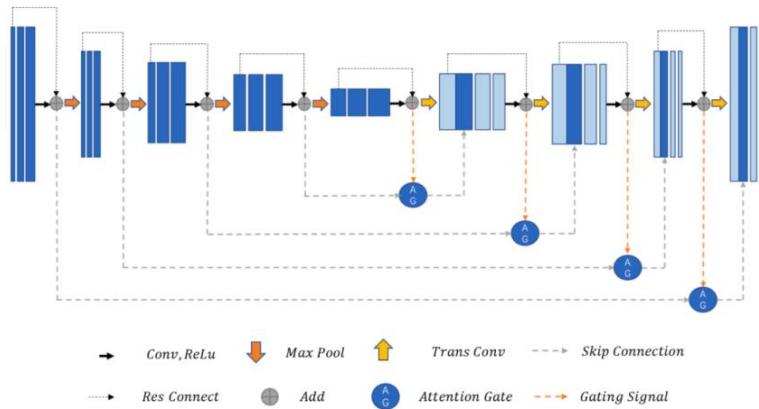


圖5、結合注意力機制與非監督式學習的U-Net網路架構 [46]

(六) 需要指導教授指導內容

本研究將使用到很多電腦視覺、影像處理、機器學習與深度學習方面的技術，例如：應用深度學習模型的瑕疵特徵擷取與分類，涉及多重CNN網路的集成模型設計與訓練；利用改良型U-Net進行語意分割的像素級瑕疵定位與辨識等。雖然目前已具有撰寫視窗與Python程式、使用OpenCV、TensorFlow、Scikit-learn函式庫的能力，但計畫涉及的影像處理技術、深度學習模型改良、機器學習模型訓練，特徵擷取及計算、辨識實驗方法設計等，仍需要教授的指導及閱讀參考文獻。此外，關於獲取樣本的特徵影像也需透過教授與TFT-LCD製造商的協助，以使系統的輸入及設計能符合實際應用的需求。

(七) 參考文獻

- [1] K. Nakashima, “Hybrid inspection system for LCD color filter panels,” in *Proceedings of the 10th Anniversary (IMTC/94), Advanced Technologies in I & M, 1994 IEEE Instrumentation and Measurement Technology Conference*, 1994, pp. 689–692.
- [2] Y. C. Chang, K. H. Chang, H. M. Meng, and H. C. Chiu, “A novel multicategory defect detection method based on the convolutional neural network method for TFT-LCD panels,” *Mathematical Problems in Engineering*, vol. 2022, article 6505372, pp. 1-14.
- [3] W. Ming, S. Zhang, X. Liu, K. Liu, J. Yuan, Z. Xie, and X. Guo, “Survey of mura defect detection in liquid crystal displays based on machine vision,” *Crystals*, vol. 11, no. 12, article 1444, 2021, pp. 1-14.
- [4] M. Chen, P. Chen, S. Wang, Y. Cui, Y. Zhang, and S. Chen, “TFT-LCD mura defect visual inspection method in multiple backgrounds,” *Journal of the Society for Information Display*, vol. 30, no. 11, 2022, 818-831.
- [5] H. P. Lu and C. T. Su, “CNNs combined with a conditional GAN for mura defect classification in TFT-LCDs,” *IEEE Transactions on Semiconductor Manufacturing*, vol. 34, no. 1, 2021, pp. 25-33.
- [6] ISO 9241-300:2008, *Ergonomics of human-system interaction Part 300: Introduction to electronic visual display requirements*. <https://www.iso.org/standard/40096.html>
- [7] C. Li, X. Zhang, Y. Huang, C. Tang, and S. Fatikow, “A novel algorithm for defect extraction and classification of mobile phone screen based on machine vision,” *Computers & Industrial Engineering*, vol. 146, article 106530, 2020, pp. 1-14.
- [8] C. Jian, J. Gao, and Y. Ao, “Automatic surface defect detection for mobile phone screen glass based on machine vision,” *Applied Soft Computing*, vol. 52, 2017, pp. 348-358.
- [9] J. Y. Lee and S. I. Yoo, “Automatic detection of region-mura defect in TFT-LCD,” *IEICE Transactions on Information and Systems*, vol. 87, no. 10, 2004, pp. 2371-2378.
- [10] Y. C. Song, D. H. Choi, and K. H. Park, “Multiscale detection of defect in thin film transistor liquid crystal display panel,” *Jpn. J. Appl. Phys.*, vol. 43, 2004, pp. 5465–5468.
- [11] D. M. Tsai, P. C. Lin, and C. J. Lu, “An independent component analysis-based filter design for defect detection in low-contrast surface images,” *Pattern Recognition*, vol. 39, 2006, pp. 1679-1694.
- [12] S. S. Fan and Y. Chuang, “Automatic detection of mura defect in TFT-LCD based on regression diagnostics,” *Pattern Recognition Letters*, vol. 31, 2010, pp. 2397–2404.
- [13] W. Pratt, S. S. Sawkar, and K. R. Reilly, “Automatic blemish detection in liquid crystal flat panel displays,” in *Proceedings of the Machine Vision Applications in Industrial Inspection VI*, January 1998; vol. 3306, pp. 25-30.
- [14] J. K. Park, B. K. Kwon, J. H. Park, and D. J. Kang, “Machine learning-based imaging system for surface defect inspection,” *International Journal of Precision Engineering and Manufacturing-Green Technology*, vol. 3, no. 3, 2016, pp. 303–310.
- [15] C. Ngo, Y. J. Park, J. Jung, R. U. Hassan, and J. Seok, “A new algorithm on the automatic TFT-LCD mura defects inspection based on an effective background reconstruction,” *Journal of the*

Society for Information Display, vol. 25, no. 12, 2017, pp. 737-752.

- [16] M. Abd Al Rahmanand and A. Mousavi, “A review and analysis of automatic optical inspection and quality monitoring methods in electronics industry,” *IEEE Access*, vol. 8, 2020, pp. 183192-183271.
- [17] Y. Zhang, Y. Zhang, and J. Gong, “A LCD screen Mura defect detection method based on machine vision,” in *Proceeding of the 2020 Chinese Control and Decision Conference (CCDC)*, 2020, pp. 4618-4623.
- [18] Y. Sun, X. Li, and J. Xiao, “A cascaded Mura defect detection method based on mean shift and level set algorithm for active-matrix OLED display panel,” *J. Soc. Inf. Display*, vol. 27, 2019, pp. 13-20.
- [19] W. Xie, H. Chen, Z. Wang, B. Liu, and L. Shuai, “Display line defect detection method based on color feature fusion,” *Machines*, vol. 10, no. 9, article 723, 2022, pp. 1-12.
- [20] W. Xie, H. Chen, Z. Wang, X. Liu, B. Liu, and L. Shuai, “Crosstalk defect detection method based on salient color channel frequency domain filtering,” *Sensors*, vol. 22, no. 14, article 5426, 2022, pp. 1-14.
- [21] Z. Wang, H. Chen, W. Xie, and H. Wang, “Color Mura defect detection method based on channel contrast sensitivity function filtering,” *Electronics*, vol. 12, no. 13, article 2965, 2023, pp. 1-13.
- [22] J. A. Suykens and J. Vandewalle, “Least squares support vector machine classifiers,” *Neural Processing Letters*, vol. 9, no. 3, 1999, pp. 293-300.
- [23] M. Mustaqeem and M. Saqib, “Principal component based support vector machine (PC-SVM): a hybrid technique for software defect detection,” *Cluster Computing*, vol. .24, no. 3, 2021, pp. 2581-2595.
- [24] S. Yu, W. Zhou, and J. Liu, “A novel defect detection method of liquid crystal display based on machine vision,” in *Proceeding of the 2022 4th International Conference on Industrial Artificial Intelligence (IAI)*, 2022, pp. 1-6.
- [25] D. H. Cho and S. L. Lee, “Defect classification using machine learning techniques for flat display panels,” *Applied Mechanics and Materials*, vol. 365, 2013, pp. 720-724.
- [26] S. S. Martinez, J. G. Ortega, J. G. Garcia, A. S. Garcia, and E. E. Estevez, “An industrial vision system for surface quality inspection of transparent parts,” *Int. J. Adv. Manuf. Technol.*, vol. 68, no. 5-8, 2013, pp. 1123-1136.
- [27] K. Yıldız, A. Buldu, and M. Demetgül, “A thermal-based defect classification method in textile fabrics with K-nearest neighbor algorithm,” *Journal of Industrial Textiles*, vol. 45, no. 5, 2016, pp. 780-795.
- [28] G. M. Torres, A. S. Souza, D. A. Ferreira, L. C. Júnior, K. Y. Ouchi, M. D. Valadão, and C. B. Carvalho, “Automated mura defect detection system on LCD displays using random forest classifier,” in *Proceeding of the 2021 IEEE International Conference on Consumer Electronics (ICCE)*, 2021, pp. 1-4.
- [29] W. Du, H. Shen, J. Fu, G. Zhang, X. Shi, and Q. He, “Automated detection of defects with low semantic information in X-ray images based on deep learning,” *Journal of Intelligent Manufacturing*, vol. 32, no. 1, 2021, pp. 141-156.

- [30] J. Lin, Y. Yao, L. Ma, and Y. Wang, "Detection of a casting defect tracked by deep convolution neural network," *International Journal of Advanced Manufacturing Technology*, vol. 97, no. 1, 2018, pp. 573-581.
- [31] T. P. Nguyen, S. Choi, S. J. Park, S. H. Park, and J. Yoon, "Inspecting method for defective casting products with convolutional neural network (CNN)," *International Journal of Precision Engineering and Manufacturing-Green Technology*, vol. 8, no. 2, 2021, pp. 583-594.
- [32] M. Kim, M. Lee, M. An, and H. Lee, "Effective automatic defect classification process based on CNN with stacking ensemble model for TFT-LCD panel," *Journal of Intelligent Manufacturing*, vol. 31, 2020, pp. 1165-1174.
- [33] L. Guo, S. Li, W. Hu, J. Wu, B. Tu, W. He, and G. Zhang, "Sub-pixel level defect detection based on notch filter and image registration," *International Journal of Pattern Recognition and Artificial Intelligence*, vol. 32, no. 6, article 1854016, 2018, pp. 1-12.
- [34] X. Feng, "Measurement and evaluation of subpixel brightness for demura," *SID Symposium Digest of Technical Papers*, vol. 50, no. 1, 2018, pp. 1122-1125.
- [35] A. Çelik, A. Küçükmanisa, A. Sümer, A. T. Çelebi, and O. Urhan, "A real-time defective pixel detection system for LCDs using deep learning based object detectors," *Journal of Intelligent Manufacturing*, vol. 33, 2022, pp. 985-994.
- [36] A. Çelik, A. Küçükmanisa, A. Sümer, A. T. Çelebi, and O. Urhan, "LCD pixel defect detection using shallow CNN based approach," in *Proceeding of the 2021 International Conference on Innovations in Intelligent Systems and Applications (INISTA)*, 2021, pp. 1-6.
- [37] J. H. Kim, K. Kong, and S. J. Kang, "Image demoireing via U-Net for detection of display defects," *IEEE Access*, vol. 10, 2022, pp. 68645-68654.
- [38] K. Oksuz, B. C. Cam, S. Kalkan, and E. Akbas, "Imbalance problems in object detection: A review," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 10, 2020, pp. 3388-3415.
- [39] H. He, Y. Bai, E. A. Garcia, and S. Li, "ADASYN: Adaptive synthetic sampling approach for imbalanced learning," in *Proceeding of the 2008 IEEE International Joint Conference on Neural Networks*, 2008, pp. 1322-1328.
- [40] C. Tan, F. Sun, T. Kong, W. Zhang, C. Yang, and C. Liu, "A survey on deep transfer learning," in *Proceedings 27th International Conference on Artificial Neural Networks and Machine Learning—ICANN*, Octobe 2018, pp. 270-279.
- [41] F. Yu, X. Xiu, and Y. Li, "A survey on deep transfer learning and beyond," *Mathematics*, vol. 10, no. 19, article 3619, 2022, pp. 1-27.
- [42] Y. Guo, H. Shi, A. Kumar, K. Grauman, T. Rosing, and R. S. Feris, "SpotTune: Transfer learning through adaptive fine-tuning," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 4805-4814.
- [43] R. Zhang, H. Tao, L. Wu, and Y. Guan, "Transfer learning with neural networks for bearing fault diagnosis in changing working conditions," *IEEE Access*, vol. 5, 2017, pp. 14347-14357.

- [44] J. Margeta, A. Criminisi, R. C. Lozoya, D. C. Lee, and N. Ayache, “Fine-tuned convolutional neural nets for cardiac MRI acquisition plane recognition,” *Comput. Methods Biomech. Biomed. Eng. Imag. Visual.*, vol. 5, no. 5, 2016, pp. 339-349.
- [45] N. Siddique, S. Paheding, C. P. Elkin, and V. Devabhaktuni, “U-net and its variants for medical image segmentation: A review of theory and applications,” *IEEE Access*, vol. 9, 2021, pp. 82031-82057.
- [46] Q. Song, W. Yao, H. Tian, Y. Guo, R. C. Muniyandi, and Y. An, “Two-stage framework with improved U-Net based on self-supervised contrastive learning for pavement crack segmentation,” *Expert Systems with Applications*, vol. 238, article 122406, 2024, pp. 1-13.
- [47] B. Xiao, Y. Liu, and B. Xiao, “Accurate state-of-charge estimation approach for lithium-ion batteries by gated recurrent unit with ensemble optimizer,” *IEEE Access*, vol. 7, 2019, pp. 54192–54202.

三、耗材、物品、圖書及雜項費用：

(一) 凡執行研究計畫所需之耗材、物品、圖書及雜項費用，均可填入本表內。

(二) 說明欄請就該項目之規格、用途等相關資料詳細填寫，以利審查。

(三) 依研究計畫實際需求擇優補助，每一計畫最高以補助新臺幣 20,000 元為限。

金額單位：新臺幣元

項目名稱	說明	單位	數量	單價	金額	備註
外接固態硬碟	SSD 4TB	個	2	4,000	8,000	
隨身碟	512GB	個	2	1,600	3,200	
DOUBLE A 影印紙	A4紙	包	2	140	280	
EPSON黑色墨水罐	003用於影印機	瓶	2	300	600	
惠普黑色墨水瓶	HPGT53XL用於影印機	瓶	2	430	860	
文具	實驗記錄與文書處理	批	1	5,000	5,000	
合計					17,940	

表C803